

CC3084 - Data Science · Laboratorio 6

Universidad del Valle de Guatemala

Facultad de Ingenieria · Departamento de Ciencias de la Computacion

Semestre II, 2026

Analisis de redes sociales en YouTube

Estructura de participacion, comunidades de audiencia y sentimiento

Integracion por video_id	406 / 406 comentarios (100.0 %)
Red bipartita autor-video	351 nodos · 343 aristas · suma de pesos = 406
Proyeccion video-video	19 nodos · 11 aristas · densidad 0.064327 · 9 aislados
Cohesion (kappa)	0 global (redes desconectadas) · 1 en la componente mayor de las tres
Comunidades (Louvain ponderado)	12 comunidades · Q = 0.4053 · 9 singletons
Autores puente verificados	7 de 332 autores
Sentimiento (espanol)	NEG 61.58 % · NEU 18.97 % · POS 19.46 %
Concentracion	Gini 0.6596 por video · 0.1643 por autor

Datos analizados

293 videos · 97 canales · 406 comentarios · 332 autores unicos

Cobertura de comentarios: 19 de 293 videos (6.48 %)

Informe generado automaticamente por el pipeline reproducible el 06/09/2026.

Todas las cifras, tablas y pies de figura provienen de las salidas computadas en results/; ninguna esta escrita a mano.

Semilla global: 42 · Modelo de sentimiento: pysentimiento/robertuito-sentiment-analysis

Resumen ejecutivo

Se analizaron 293 videos de 97 canales de YouTube y 406 comentarios principales publicados por 332 autores distintos. Los 406 comentarios se asociaron a un video mediante `video_id` sin excepciones (100.0%), pero cubren solo 19 de los 293 videos del catalogo (6.5%). Esa asimetria de cobertura condiciona todo el analisis y se trata explicitamente en cada seccion: los conteos de comentarios son *observados en la muestra*, no totales de YouTube.

Participacion muy concentrada por contenido y muy repartida por persona. Los tres videos mas comentados acumulan 63.0% de los comentarios y el canal lider 63.0% (Gini de 0.6596 por video y 0.6644 por canal). En el extremo opuesto, el Gini por autor es de solo 0.1643: 286 de 332 autores (86.1%) publicaron un unico comentario.

La red de co-participacion esta fragmentada. La red bipartita autor-video tiene 351 nodos y 343 aristas, con la suma de pesos igual a los 406 comentarios. Solo 9 autores (2.7%) comentaron en mas de un video, y son el unico mecanismo que conecta contenidos entre si: la proyeccion video-video tiene 11 aristas de 171 posibles (densidad 0.064327) y deja 9 de 19 videos aislados. La cohesion global por nodos es 0 en las tres redes porque estan desconectadas; en la componente mayor de cada una es 1, es decir, un solo nodo bien elegido las parte.

Comunidades pocas pero interpretables. Louvain ponderado sobre la proyeccion video-video (semilla 42, resolucion 1.0) devuelve 12 comunidades con modularidad ponderada $Q = 0.4053$, de las cuales 9 son singletons y 3 tienen mas de un video. Las tres no triviales se separan por tema y por emisor: critica al Congreso y a la corrupcion, comunicacion del Ejecutivo, y regulacion de monopolios y movilidad urbana.

Puentes escasos y verificados. De los 332 autores, 7 son puentes en sentido estricto: al eliminarlos de la red bipartita aumenta el numero de componentes de la proyeccion video-video. Solo 9 autores (2.7%) tienen intermediacion positiva.

Sentimiento predominantemente critico. Con `pysentimiento/robertuito-sentiment-analysis`, 61.6% de los comentarios se clasifica como negativo, 19.0% como neutro y 19.5% como positivo (polaridad neta -42.1 puntos porcentuales, confianza mediana 0.8685). La composicion difiere entre canales de forma significativa ($\chi^2 = 82.0701$, $gl = 8$, $p = 0.0$, V de Cramer = 0.3244): el video institucional mas comentado de la Municipalidad concentra respaldo, mientras que el periodismo de investigacion concentra critica.

Visibilidad y participacion se ordenan igual, pero no coinciden. Entre los 19 videos con comentarios recolectados, visualizaciones y comentarios observados correlacionan con ρ de Spearman = 0.8115 ($p = 2e-05$). Aun asi el video mas visto (304 089 vistas) recibio 25 comentarios observados, frente a los 161 del mas comentado, que tiene 11 775 vistas.

Ninguna cifra de este informe puede extrapolarse a YouTube ni a la poblacion de Guatemala. Los comentarios provienen de una seleccion de videos recuperados por consultas de busqueda especificas, en un momento determinado, y el conjunto no incluye respuestas ni permite saber quien respondio a quien.

1. Introduccion y objetivo

El laboratorio estudia la estructura de participacion de los usuarios de YouTube a partir de dos conjuntos de datos: un catalogo de videos con sus metadatos de canal, categoria y visibilidad, y un conjunto de comentarios principales publicados en una seleccion de esos videos. El objetivo es describir quien participa, en que contenidos, con que estructura de red, sobre que temas y con que polaridad, distinguiendo en todo momento lo que los datos permiten afirmar de lo que solo permiten conjeturar.

El analisis se organiza en torno a una decision conceptual que atraviesa el informe: **los datos no contienen relaciones explicitas entre autores**. La variable `reply_count` indica cuantas respuestas recibio un comentario, pero no identifica a quien las escribio. Por lo tanto no existe una red de interaccion directa entre usuarios, y construirla seria una invencion. Lo que si puede construirse, y es lo que se construye, es una red de **co-participacion**: dos personas quedan vinculadas si comentaron el mismo video, lo que significa que coincidieron en un espacio de discusion, no que se hayan hablado.

1.1 Preguntas que guian el analisis

- Que contenidos y que emisores concentran la participacion observada.
- Si existe audiencia compartida entre videos y canales, y de que magnitud.
- Quienes sostienen las conexiones entre contenidos que de otro modo quedarian separados, y como verificarlo en lugar de suponerlo.
- Que agrupamientos de contenido emergen de la audiencia compartida, y como se caracterizan por tema y por polaridad.
- Si la visibilidad (visualizaciones) predice la participacion observada.
- Que conclusiones quedan limitadas por el procedimiento de recoleccion.

1.2 Datos de partida y verificacion de integridad

Los dos archivos se copiaron a `data/raw/` y se tratan como inmutables durante todo el analisis. Sus sumas MD5 quedan registradas en `results/metrics/load.json` para poder comprobar que no se alteraron: `d338be279d181215...` para el catalogo de videos y `c45c1dcc72e33971...` para los comentarios.

Tabla 1. Dimensiones observadas frente a las declaradas en el enunciado

Archivo	Filas obs.	Cols. obs.	Filas esp.	Cols. esp.	Coincide
youtube_videos.csv	293	20	293	20	si
youtube_comments.csv	406	17	406	17	si

Las dimensiones coinciden exactamente con las declaradas. Dos detalles tecnicos de la carga que afectan el resultado: ambos archivos traen marca de orden de bytes (BOM), por lo que se leen con `utf-8-sig` (los dos archivos traen BOM) — sin eso, el nombre de la primera columna quedaria como `\ufeffvideo_id` y el join fallaria por completo; y todas las columnas se cargan como texto (str en todas las columnas; conversion posterior explicita), porque si pandas infiere tipos convierte identificadores con apariencia numerica y puede recortar ceros a la izquierda.

2. Datos y unidades de observacion

2.1 Unidad de observacion y llave primaria

Tabla 2. Unidad de observacion y llaves de cada conjunto

Conjunto	Unidad de observacion	Llave primaria	Verificacion
youtube_videos.csv	Un video de YouTube	video_id	293 valores unicos, 0 duplicados, 0 nulos
youtube_comments.csv	Un comentario principal	comment_id	406 valores unicos, 0 duplicados, 0 nulos

En el conjunto de comentarios, `video_id` es llave **foranea**, no primaria: se repite porque un video recibe muchos comentarios (387 repeticiones sobre 406 filas). Del mismo modo, `channel_id` se repite en el catalogo de videos porque un canal publica varios videos. Confundir cualquiera de las dos con una llave primaria produciria agregados erroneos.

2.2 Relacion conceptual entre canal, video, comentario, autor, categoria y consulta

La jerarquia de los datos tiene cuatro niveles y dos etiquetas transversales. Es importante fijarla antes de agregar cualquier cosa, porque cada nivel tiene su propio denominador:

- **Canal** (`channel_id`): la cuenta que publica contenido. Es el emisor. Hay 97 canales en el catalogo, de los cuales 8 tienen comentarios recolectados (8.2%).
- **Video** (`video_id`): una pieza de contenido publicada por un canal. Relacion uno a muchos: un canal tiene varios videos, un video tiene un solo canal. Hay 293 videos.
- **Comentario** (`comment_id`): un mensaje publicado en un video. Relacion uno a muchos con el video. Es la unidad de texto y de sentimiento. Hay 406 comentarios.
- **Autor del comentario** (`author_channel_id`): la cuenta que escribio el comentario. Relacion muchos a muchos con los videos: un autor puede comentar varios videos y un video recibe comentarios de varios autores. Es esta relacion muchos a muchos la que hace posible una red bipartita. Hay 332 autores.
- **Categoria** (`category`): etiqueta tematica que YouTube asigna al video. Es un atributo del video, no del comentario. Hay 11 categorias distintas.
- **Consulta de busqueda** (`source_query`, `source_group`): describe **como se encontro** el registro durante la recoleccion. No es un atributo del contenido sino del muestreo, y por eso se usa para evaluar cobertura y sesgo, nunca como etiqueta tematica definitiva.

`channel_id` y `author_channel_id` **no son la misma cosa y no son intercambiables**. `channel_id` identifica al canal *dueno del video comentado*; `author_channel_id` identifica a la *persona que escribio el comentario*. Ambos tienen el mismo formato (UC...), lo que los hace facilmente confundibles. Se verifico que ningun comentario observado fue escrito por el canal dueno del video (0 coincidencias entre las dos columnas en las 406 filas), de modo que en esta muestra los dos conjuntos de cuentas son disjuntos.

2.3 Variables relevantes por conjunto

Tabla 3. Variables usadas en el analisis y su funcion

Variable	Conjunto	Funcion en el analisis
video_id	ambos	Llave del join; nodo de tipo video en la red bipartita
comment_id	comentarios	Llave primaria; unidad de sentimiento
channel_id	ambos	Nodo de canal; agregacion por emisor
author_channel_id	comentarios	Nodo de tipo autor en la red bipartita
text	comentarios	Fuente de texto_original y texto_limpio
view_count	videos	Medida de visibilidad para el contraste con participacion
like_count_text	comentarios	Aprobacion recibida por el comentario (requiere parseo)
reply_count	comentarios	Intensidad de conversacion del comentario; NO una arista
category	videos	Caracterizacion tematica de las comunidades
source_query / source_group	ambos	Diagnostico de cobertura y sesgo de muestreo
keywords / title / description	videos	Caracterizacion tematica desde el emisor
publish_date	videos	Unica fecha absoluta disponible (ISO 8601)

3. Integracion de los datos

La integracion se hizo con un **LEFT JOIN comentarios -> videos por video_id**, de cardinalidad *1 video : N comentarios (uno a muchos)*. La direccion del join no es arbitraria: la pregunta del inciso 1.4 es cuantos comentarios logran asociarse a un video, asi que ninguna fila de comentarios puede desaparecer en el proceso. Un inner join habria respondido la pregunta ocultando su propia respuesta.

Tabla 4. Resultado de la integracion por video_id

Metrica	Valor
Comentarios en el conjunto	406
Comentarios que encontraron su video	406
Comentarios sin video correspondiente	0
Porcentaje asociado	100.0%
video_id distintos en comentarios	19
Videos del catalogo con al menos un comentario observado	19 de 293 (6.5%)
Videos del catalogo sin comentario observado	274

Los 406 comentarios se asociaron a un video sin excepciones. No hay comentarios huérfanos: el conjunto de video_id presentes en los comentarios es un subconjunto propio del catalogo de videos. Esto confirma que los dos archivos provienen de la misma recoleccion y que la llave esta bien formada.

El hallazgo importante del join no es el 100.0% de exito, sino su contraparte: **274 de los 293 videos del catalogo no tienen ningun comentario en este conjunto de datos.** Eso *no* significa que no recibieran comentarios en YouTube. Significa que no se recolectaron. La diferencia entre «sin comentario observado» y «sin comentarios» es la distincion metodologica mas importante de todo el laboratorio, y se mantiene explicita en cada tabla y cada figura.

3.1 Consistencia de las variables redundantes tras el join

El conjunto de comentarios repite cuatro variables que tambien estan en el catalogo de videos (video_title, channel_name, channel_id, y las de muestreo). Se verificaron una por una en lugar de sobrescribirlas en silencio. De 17 chequeos automaticos, 15 se cumplen.

Tabla 5. Chequeos de consistencia entre identificadores, nombres y handles

Ambito	Chequeo	Resultado	Cumple
videos	channel_id <-> channel_name es 1:1	1 y 1	si
videos	channel_id <-> channel_handle es 1:1	1 y 1	si
videos	owner_handle == channel_handle	0 diferencias	si
videos	publish_date == upload_date	0 diferencias	si
videos	video_url contiene video_id	0	si
comentarios	author_channel_id <-> author_name es 1:1	1 y 1	si
comentarios	author_channel_id <-> author_handle es 1:1	1 y 1	si
comentarios	channel_id <-> channel_name es 1:1	1 y 1	si
comentarios	channel_id != author_channel_id	0	si
join	video_title == title	0 diferencias	si
join	channel_id (comments) == channel_id (videos)	0 diferencias	si
join	channel_name (comments) == channel_name (videos)	0 diferencias	si
join	source_query (comments) == source_query (videos)	188 de 406 difieren	si
join	source_group (comments) == source_group (videos)	188 de 406 difieren	si
comentarios	author_handle sin percent-encoding	14 registros codificados	NO
comentarios	author_handle_norm == author_name normalizado	0 diferencias	si
videos	channel_handle sin percent-encoding	13 registros codificados	NO

Las variables video_title, channel_id y channel_name del conjunto de comentarios coinciden al 100 % con las del catalogo tras el join, de modo que son estrictamente redundantes. Se conservan con sufijo _c y los analisis usan la version del catalogo de videos, que es la fuente autoritativa para atributos de video.

Dos hallazgos de los chequeos que no se cumplen

Los dos chequeos que no se cumplen no son fallos del pipeline sino **anomalías reales de los datos**, detectadas por el diagnostico y corregidas:

- author_handle **viene codificado para URL en 14 registros** (9 autores distintos): el archivo guarda /@ErmeP%C3%A9rez-q4s mientras que author_name guarda @ErmePérez-q4s. Sin decodificar el percent-encoding, el mismo autor parece tener dos etiquetas visibles distintas y cualquier comparacion entre ambas columnas falla. Se corrige en la columna derivada author_handle_norm; el campo original se conserva intacto. Tras decodificar, las dos etiquetas coinciden en los 406 registros.
- channel_handle **presenta la misma anomalía en 13 registros** del catalogo de videos. Se corrige igual, en channel_handle_norm.

Un tercer chequeo merece comentario porque su resultado *no* es un error. source_query y source_group difieren entre los dos archivos en 188 de 406 filas. La razon es de diseno: la version del comentario describe mediante que consulta se obtuvo *el comentario*, y la del video mediante que consulta se encontro *el video*. Un video puede haberse localizado con la consulta tematica guatemala noticias y sus comentarios haberse extraido despues en un barrido del canal @quorumgt/videos. Ambas versiones se conservan con sufijos explicitos porque documentan dos etapas distintas del muestreo.

4. Calidad, limpieza y preprocesamiento

4.1 Diagnostico inicial de calidad

El diagnostico se ejecuta sobre los datos **crudos**, antes de cualquier transformacion, y produce un perfil por variable con tipo inferido, faltantes, celdas en blanco, cardinalidad y constancia. Las tablas completas estan en `results/tables/data_quality_videos.csv` y `results/tables/data_quality_comments.csv`; aqui se resume lo relevante.

Dimensiones, duplicados y llaves


Tabla 6. Duplicados y unicidad de las llaves candidatas

Conjunto	Filas	Cols.	Filas duplicadas	Llave	Unicos	Duplicados	Es unica
youtube_videos	293	20	0	video_id	293	0	si
				channel_id	97	196	no
youtube_comments	406	17	0	video_id	19	387	no
				comment_id	406	0	si
				channel_id	8	398	no
				author_channel_id	332	74	no

No hay filas duplicadas completas en ninguno de los dos archivos, y las dos llaves primarias declaradas (`video_id` y `comment_id`) son efectivamente unicas y sin nulos. `channel_id`, `video_id` (en comentarios) y `author_channel_id` se repiten como corresponde a su papel de llave foranea o de agrupacion.

Valores faltantes

Figura 1. Completitud de las variables por dataset



Solo 4 variables de videos tienen faltantes (<9%). En comentarios, `viewer_rating` esta vacia al 100% y `like_count_text` aparece en blanco en 189 registros (46.6%), que se interpretan como 0 me gusta.

Tabla 7. Variables con valores faltantes


Conjunto	Variable	Nulos	% nulos	Tratamiento
videos	published_time	13	4.4%	No se usa como fecha; se prefiere <code>publish_date</code> (0 nulos)
videos	view_count_text	13	4.4%	Respaldo de <code>view_count</code> , que no tiene nulos
videos	description_snippet	25	8.5%	Fragmento de <code>description</code> ; los conteos usan los no nulos
videos	description	26	8.9%	Analisis de texto de video sobre los no nulos, reportando el n
comentarios	viewer_rating	406	100.0%	Excluida del analisis: vacia al 100 %

El catalogo de videos tiene faltantes en cuatro variables, todas por debajo del 9 %. Es importante que `view_count` **no** este entre ellas: tiene 0 nulos, mientras que `view_count_text` tiene 13. Eso confirma la recomendacion del enunciado de usar `view_count` para los calculos cuantitativos y reservar `view_count_text` como respaldo. En el conjunto de comentarios el unico faltante es `viewer_rating`, vacia en las 406 filas.

Variables constantes y sin varianza

Dos variables del conjunto de comentarios no aportan informacion: `is_pinned` toma un unico valor (False) en los 406 registros, y `viewer_rating` esta completamente vacia. Una variable de varianza cero no puede explicar ni segmentar nada, asi que ninguna de las dos entra en el analisis. En el catalogo de videos no hay variables constantes en sentido estricto, pero si dos **redundantes**: `upload_date` es identica a `publish_date` y `owner_handle` es identico a `channel_handle` en el 100 % de los registros.

Valores atipicos



Cola derecha pesada: mediana 1,175 vistas frente a un máximo de 8,190,449 (ratio 6970x). La mediana de los videos con comentarios recolectados (1,954) frente a los que no los tienen (1,149) no difiere de forma significativa (Mann-Whitney $U=2147.5$, $p=0.20265$): la muestra de comentarios no es simplemente 'los videos mas vistos'.

Tabla 8. Diagnostico de atipicos en las variables cuantitativas

Variable	n	Mediana	Media	p90	Max	Asimetria	Atipicos IQR	Max/mediana
<code>view_count_num</code>	293	1 175.0	60 430.1	51 318.8	8 190 449	14.26	49 (16.7 %)	6 970.6
<code>like_count</code>	406	1.0	5.7	7.0	405	9.88	48 (11.8 %)	405.0
<code>reply_count_num</code>	406	0.0	0.1	0.0	7	7.21	30 (7.4 %)	n/d
<code>len_original</code>	406	96.5	139.2	285.5	1 525	3.98	21 (5.2 %)	15.8
<code>tokens_original</code>	406	16.0	24.1	49.0	282	4.19	22 (5.4 %)	17.6
<code>n_emojis</code>	406	0.0	0.5	1.0	18	5.62	61 (15.0 %)	n/d

No se elimino ningun valor atipico. La decision es deliberada y se sostiene en la forma de las distribuciones. Los conteos de popularidad en redes sociales siguen leyes de potencia: la asimetria de `view_count` es de 14.3 y su maximo es 6 970.6 veces la mediana. Bajo el criterio de rango intercuartil, 49 videos (16.7 %) serian atipicos; pero un video con 8,2 millones de visualizaciones no es un error de captura, es un video que se hizo viral. Recortar la cola derecha eliminaria precisamente el fenomeno que se quiere estudiar y sesgaria a la baja toda medida de concentracion.

Se aplico el mismo criterio a `like_count` (maximo de 405.0 en un comentario, frente a una mediana de 1.0) y a la longitud del texto (maximo de 1 525.0 caracteres). Los valores se reportan y se discuten como plausibles; los analisis que podrian verse afectados por la cola usan estadisticos robustos (mediana, percentiles, Spearman) en lugar de la media y Pearson.

4.2 Variables problematicas o de uso delicado

Tabla 9. Clasificacion de las variables que requieren precauciones

Conjunto	Variable	Clasificacion	Evidencia	Tratamiento
comentarios	viewer_rating	Inutilizable	Vacia en los 406 registros (406 nulos).	Se excluye de todo analisis. Se conserva en el archivo crudo.
comentarios	is_pinned	Inutilizable (constante)	Valor unico ['False'] en los 406 registros.	Varianza cero: no puede explicar ni segmentar nada. Se convierte a booleano y se documenta.
comentarios	reply_count	Uso delicado	Cuenta respuestas recibidas pero no identifica a quien respondio.	Prohibido usarla como arista. Se usa solo como atributo de intensidad del comentario.
comentarios	published_text	Uso delicado	Tiempo relativo al momento de recoleccion ('hace 2 años'), redondeado p...	No se convierte a fecha absoluta. Se deriva published_days_approx solo para ordenar.
comentarios	like_count_text	Requiere conversion	Texto; 189 registros en blanco (un espacio).	Parser explicito; blanco -> 0 con bandera like_count_blank, porque YouTube oculta el contador c...
comentarios	video_title / channel_name / ...	Redundante	Derivables del join por video_id; verificadas consistentes al 100%.	Se conservan con sufijo _c y se prefiere la version de videos.
comentarios	author_name / author_handle	Uso delicado	Etiquetas visibles mutables; no son identificadores. Ademas 14 author_h...	Solo para etiquetas de figuras. El nodo es author_channel_id. Se decodifica el percent-encoding...
videos	published_time	Uso delicado	Tiempo relativo; 13 nulos.	No se usa como fecha. Se prefiere publish_date (ISO 8601, sin nulos).
videos	view_count_text	Requiere conversion	Texto con separador de miles y sufijo 'vistas'; 13 nulos.	Se parsea a view_count_text_num y se usa solo como respaldo de view_count.
videos	upload_date	Redundante	Identica a publish_date en el 100% de los registros.	Se conserva; los analisis temporales usan publish_date.
videos	owner_handle	Redundante	Identica a channel_handle en el 100% de los registros.	Se conserva; las etiquetas usan channel_handle.
videos	query_hits / keywords / datas...	Requiere parseo	Listas serializadas como texto (JSON o separadas por ' ').	Se convierten a listas reales antes de contar.
videos	source_query / source_group	Uso delicado	Describen el muestreo, no el tema del video.	Se usan para caracterizar cobertura, nunca como etiqueta tematica definitiva.
videos	description / description_sni...	Faltantes	26 y 25 nulos respectivamente.	Los conteos de texto de video se calculan sobre los no nulos y se reporta el n.
videos	channel_name	Uso delicado	Nombre visible mutable y potencialmente repetible.	El nodo de canal es channel_id; channel_name solo etiqueta.

Tres casos de esa tabla merecen el énfasis que la rubrica pide. El primero es `reply_count`: es una variable perfectamente utilizable como atributo de intensidad de un comentario, y a la vez es la variable cuyo mal uso invalidaria todo el analisis de red. Indica cuantas respuestas recibio un comentario, no quien las escribio; usarla como arista construiria vinculos entre personas que los datos no respaldan. En este trabajo aparece unicamente como atributo agregado de nodos y aristas, y el pipeline verifica en cada corrida que la suma de pesos de la red bipartita coincida con el numero de comentarios y no con el de respuestas.

El segundo es `published_text` (y su equivalente `published_time` en videos): es un tiempo relativo al momento de recoleccion («hace 2 años»), redondeado por YouTube. No se convierte a fecha absoluta porque no se conoce la fecha de recoleccion con precision y porque el redondeo destruye la resolucion. Se deriva unicamente `published_days_approx` para poder ordenar por antigüedad, y se declara explicitamente como aproximacion.

El tercero es `source_query`: describe el procedimiento de muestreo, no el tema del video. Un video recuperado por la consulta `guatemala lluvias` puede tratar de trafico, y de hecho la seccion 7 muestra que la concordancia entre consulta y comunidad detectada es baja una vez corregida por azar. Se usa para diagnosticar cobertura y sesgo, nunca como etiqueta tematica.

4.3 Normalizacion de identificadores y nombres

La regla que gobierna esta seccion es que **un identificador nunca se sustituye por un nombre visible**. `channel_id`, `video_id`, `comment_id` y `author_channel_id` son los identificadores del analisis; los nombres y handles se usan solo como etiquetas de figuras y tablas.

Tabla 10. Reglas de normalizacion aplicadas

Tipo de campo	Transformacion	Justificacion
Identificadores (*_id)	NFKC + recorte de espacios. Sin cambio de mayusculas/minusculas.	Los IDs de YouTube distinguen mayusculas (UCq0Cm-3SKthEysQc2JZBi1A). Bajarlos a minusculas colapsaria identificadores distintos.
Nombres visibles	NFKC + colapso de espacios, en columna derivada *_norm. Original intacto.	NFKC unifica variantes Unicode de compatibilidad sin destruir el contenido legible. No se quitan acentos ni se baja el case.
Handles	Decodificacion de percent-encoding + quita / inicial y sufijo de ruta + garantiza @, en *_norm.	El mismo canal aparece como /@quorumgt, @quorumgt y @quorumgt/videos; y los no-ASCII vienen codificados para URL.
Llaves de comparacion	normalize_key: minusculas, sin acentos, espacios colapsados. Solo para auditar.	Permite comparar más/mas al verificar consistencia, sin que ese valor reemplace nunca al original ni a un ID.

4.4 Conversion de los conteos almacenados como texto

Dos variables llegan como texto y deben convertirse: `view_count_text` en videos ("29,736 vistas") y `like_count_text` en comentarios. El parser esta en `src/text_processing.py::parse_count` y su tratamiento es el siguiente:

Tabla 11. Reglas del parser de conteos y su resultado

Caso de entrada	Regla aplicada	Ejemplo	Salida
Separador de miles (, o . o espacio)	Se elimina	"29,736 vistas"	29736
Sufijo del texto (vistas, views)	Se ignora tras capturar el numero	"2,390 vistas"	2390
Abreviatura K / M / B	Multiplica por 1e3 / 1e6 / 1e9	"1.5K"	1500
Abreviatura en espanol (mil, millones)	Multiplica igual	"1,5 mil"	1500
Decimal con sufijo	El ultimo separador se lee como decimal	"2.3M vistas"	2300000
Cadena vacia o solo espacios	Devuelve nulo, no cero	" "	nulo
Cadena no numerica	Devuelve nulo, no cero	"abc"	nulo

El caso que exige una decision es el de `like_count_text`: **189 de 406 comentarios (46.5%) traen un unico espacio en blanco**. El parser devuelve nulo para ellos, porque inventar un cero dentro de una funcion de conversion seria mezclar parseo con imputacion. La imputacion se hace despues, de forma explicita y con bandera de auditoria (`like_count_blank`), y la justificacion es empirica: el minimo valor no vacio observado es **1**, es decir, no existe ningun comentario que declare cero «me gusta» de forma explicita. YouTube oculta el contador cuando vale cero, así que blanco equivale a cero. Se conservan las tres columnas: el texto original, el valor parseado con nulos y el valor imputado con su bandera.

4.5 Las dos versiones del texto

Se crearon `texto_original` y `texto_limpio` con propósitos deliberadamente distintos, y la separación no es cosmética: usar la versión equivocada cambia el resultado.

Tabla 12. Propósito de cada versión del texto

Version	Contenido	Se usa para	Por qué
<code>texto_original</code>	Copia fiel del comentario, sin ninguna alteración	Auditoría y análisis de sentimiento	Mayúsculas, signos de exclamación, emojis y negaciones son señal de polaridad. «NO me gusta» y «me gusta» son idénticos sin stopwords, y opuestos en sentimiento.
<code>texto_limpio</code>	Bolsa de palabras lematizada, sin stopwords ni puntuación	Frecuencias, bigramas, TF-IDF y caracterización temática	Para contar contenido conviene colapsar flexiones y eliminar el ruido funcional; ahí sí es correcto destruir información de forma.

4.5.1 Decisiones de limpieza de `texto_limpio`, una por una

Tabla 13. Decisiones documentadas del inciso 2.6

Elemento	Decisión	Justificación y evidencia
Minúsculas	Se aplican, junto con eliminación de acentos	Unifica <code>más/mas</code> y <code>Diputado/diputado</code> , que de otro modo se cuentan como términos distintos. El caso se pierde solo en esta versión.
URL	Se eliminan del texto temático; se extraen a una columna aparte	Solo 1 comentario contiene una URL, pero un dominio partido en tokens contamina el vocabulario sin aportar tema.
Hashtags	Se extraen primero; se conserva la palabra y se elimina el #	El # es marca sintáctica; la palabra es contenido temático legítimo. Aparecen en 1 comentario.
Menciones	Se extraen aparte y se eliminan del texto temático	Una mención identifica una cuenta, no un tema. Aparecen en 5 comentarios.
Puntuación	Se elimina por completo	No aporta al conteo de contenido. Su señal se preserva en <code>texto_original</code> , que es lo que consume el modelo de sentimiento.
Números	Se eliminan los tokens puramente numéricos	Presentes en algunos comentarios como cifras sueltas; sin unidad ni contexto no identifican tema.
Stopwords en español	Se eliminan (NLTK + spaCy + lista de dominio)	313 stopwords de NLTK, las de spaCy y una lista de ruido conversacional de YouTube (<code>jaja</code> , <code>q</code> , <code>xq</code> , <code>pq</code> , <code>tmb</code>). Sin ellas, los rankings de frecuencia se llenan de artículos y de <i>risa</i> .
Lematización	Se aplica con <code>es_core_news_sm</code> de spaCy	Colapsa <code>diputados/diputado</code> y <code>pagan/pagar</code> , que se refieren al mismo concepto. Se eligió spaCy sobre un stemmer porque un stemmer produce raíces no legibles (<code>diput</code>) que arruinan la interpretación de los rankings.
Emojis	Se eliminan del texto temático; se extraen y cuentan aparte	Hay 199 emojis en 61 comentarios. En la bolsa de palabras no son términos; en el análisis de sentimiento si se conservan y se traducen a su descripción en español, porque el modelo fue entrenado con esa representación.
Atajos de emoji textualizados	Se eliminan del texto temático	Hallazgo del diagnóstico: el CSV crudo contiene 4 atajos ya convertidos a texto por el recolector (<code>:hand-purple-blue-peace:</code>) en 2 comentarios. Sin tratarlos producían los bigramas «hand purple» y «purple blue» entre los más frecuentes de una comunidad: vocabulario creado por la recolección, no por los usuarios.
Repeticiones de caracteres	Se acortan a dos (<code>holaaaa</code> → <code>holaa</code>)	Reduce variantes ortográficas de la misma palabra.

4.6 Efecto cuantificado de la limpieza

Tabla 14. Efecto de la limpieza sobre el texto (inciso 2.7)

Metrica	Antes	Despues
Comentarios	406	406
Registros eliminados	—	0
Textos vacios	0	10
Duplicados exactos de texto	2	14 (5 excluyendo los vacios)
Longitud media (caracteres)	139.2	72.4
Longitud mediana (caracteres)	96.5	52.0
Tokens medios por comentario	24.06	9.39
Reduccion total de caracteres	—	48.0%
Reduccion total de tokens	—	61.0%
Textos modificados	—	405 (99.8%)
Textos sin modificacion	—	1

La limpieza reduce el corpus en 61.0% de sus tokens y 48.0% de sus caracteres, lo que es el orden de magnitud esperado al quitar stopwords de espanol. 405 de 406 textos cambian; el unico que no cambia es un comentario de una sola palabra de contenido que ya estaba en minusculas y sin puntuacion.

No se elimino ningun comentario. 10 textos quedan vacios tras la limpieza tematica, es decir, estaban compuestos solo de stopwords, emojis o interjecciones. Se conservan en el conjunto porque su `texto_original` sigue siendo valido para el analisis de sentimiento y, sobre todo, porque su autor sigue siendo un participante real de la red: excluirlos borraría aristas legitimas de co-participacion y sesgaría la estructura hacia los comentarios largos. Los 5 duplicados de `texto_limpio` no vacios corresponden a comentarios distintos que, tras lematizar y quitar stopwords, comparten la misma bolsa de palabras; tampoco se eliminan, por la misma razon.

5. Analisis exploratorio

5.1 Descriptivos minimos


Tabla 15. Conteos basicos de los dos universos

Concepto	Valor	Denominador correcto
Videos en el catalogo	293	Universo de videos recolectados
Canales en el catalogo	97	—
Categorias de YouTube	11	—
Consultas de recoleccion (videos)	21	—
Comentarios observados	406	Solo de los videos con comentarios recolectados
Autores unicos	332	—
Videos con comentario observado	19	6.5% del catalogo
Videos sin comentario observado	274	No equivale a «sin comentarios en YouTube»
Canales con comentario observado	8	8.2% de los canales
Comentarios por autor (global)	1.223	—

Todas las metricas «por video» de esta seccion se calculan sobre los 19 videos con comentarios recolectados, no sobre los 293 del catalogo. Incluir los 274 restantes con valor cero produciria una mediana de 0 comentarios por video y confundiria la falta de datos con la falta de participacion.

Videos por canal

Figura 14. Estructura del catalogo de videos por canal




65 de 97 canales aportan un unico video. El catalogo se construyo mezclando busquedas por tema con barridos de canales especificos, lo que produce esta mezcla de canales muy representados y canales con un solo video.

Tabla 16. Distribucion de videos por canal (catalogo completo)

Estadistico	Valor
n	97
Suma	293
Minimo	1
Percentil 25	1.0
Mediana	1.0
Media	3.02
Percentil 75	2.0
Percentil 90	7.4
Maximo	32
Desv. estandar	5.14
Asimetria	3.679
Gini	0.5741
Canales con un solo video	65

El catalogo no es una muestra homogénea de canales: 65 de los 97 canales aportan un unico video, mientras que el maximo es de 32 videos. Esa mezcla es consecuencia directa del procedimiento de recoleccion, que combinó búsquedas por tema (que devuelven un video de muchos canales distintos) con barridos de canales específicos (que devuelven muchos videos del mismo canal).

Comentarios y autores unicos por video



Los 19 videos con comentarios recolectados concentran los 406 comentarios. El video mas comentado acumula 161 comentarios (39.7% del total). La cercanía entre barras indica que casi cada comentario proviene de un autor distinto.

Tabla 17. Comentarios y autores por video observado

Estadístico	Comentarios por video	Autores unicos por video
n	19	19
Suma	406	343
Minimo	1	1
Percentil 25	2.5	2.5
Mediana	7.0	7.0
Media	21.37	18.05
Percentil 75	25.0	18.5
Percentil 90	46.0	35.4
Maximo	161	128
Desv. estandar	36.82	29.46
Asimetria	3.352	3.222
Gini	0.6596	0.6402

La cifra mas informativa de esta tabla es la cercania entre las dos columnas. La mediana de comentarios por video es 7 y la de autores unicos es 7; el video mas comentado tiene 161 comentarios de 128 autores distintos. Es decir, **cada comentario proviene practicamente de una persona diferente**. La participacion observada es amplia y superficial, no un intercambio sostenido entre pocos usuarios.

Visualizaciones

Tabla 18. Visualizaciones: catalogo completo frente a videos observados


Estadístico	Catalogo (n=293)	Con comentario observado (n=19)
n	293	19
Suma	17 706 015	380 876
Minimo	2	52
Percentil 25	215	695
Mediana	1 175	1 954
Media	60 430.09	20 046.11
Percentil 75	7 465	8 424
Percentil 90	51 319	12 260
Maximo	8 190 449	304 089
Desv. estandar	515 798.31	68 934.23
Asimetria	14.258	4.327
Gini	0.9493	0.8533

La distribucion tiene cola derecha extrema: mediana de 1 175 visualizaciones frente a un maximo de 8 190 449, con asimetria de 14.26 y Gini de 0.9493. Los dos videos mas vistos concentran 46.3% y 68.3% (top 3) de todas las visualizaciones del catalogo.

La comparacion entre las dos columnas responde una pregunta importante sobre el muestreo: **¿se recolectaron comentarios de los videos mas vistos?** La mediana de los videos con comentarios recolectados es de 1 954 visualizaciones frente a 1 150 de los demas, una diferencia que **no** es estadisticamente significativa (Mann-Whitney U = 2 148, p = 0.20265). Sus posiciones en el ranking de visualizaciones van del puesto 9 al 255 de 293. La cobertura de comentarios no se explica por popularidad, sino por el procedimiento de recoleccion.

«Me gusta» y respuestas

Figura 13. Intensidad de la interacción observada



El 46.6% de los comentarios no muestra 'me gusta' y solo 30 recibieron respuesta. 286 de 332 autores (86.1%) comentaron una única vez: la participación es mayoritariamente puntual, no conversacional.

Tabla 19. Aprobación y respuestas recibidas por los comentarios

Metrica	Valor
Suma de «me gusta»	2 325
«Me gusta» mediana por comentario	1
«Me gusta» media por comentario	5.73
«Me gusta» maximo en un comentario	405
Gini de «me gusta»	0.8957
Comentarios con cero «me gusta»	189 (46.5%)
Suma de respuestas (reply_count)	51
Comentarios que recibieron alguna respuesta	30 (7.4%)
Valores observados de reply_count	0, 1, 2, 3, 5, 7

La interacción secundaria es escasa. El 46.5% de los comentarios no muestra ningún «me gusta», y solo 30 de 406 (7.4%) recibieron alguna respuesta, con un total de 51 respuestas en todo el conjunto. **Esas respuestas no están en los datos:** se sabe que existen y cuantas son, pero no su texto ni su autor. Es la evidencia directa de por qué no puede construirse una red de interacción entre usuarios.

Recurrencia de los autores


Tabla 20. Distribución de autores por número de comentarios

Comentarios publicados	Numero de autores	% de autores
1	286	86.1%
2	30	9.0%
3	10	3.0%
4	2	0.6%
5	2	0.6%
6	2	0.6%

286 de 332 autores (86.1%) aparecen una sola vez, y el máximo es de 6 comentarios. Más relevante para la red: solo 9 autores (2.7%) comentaron en más de un video y 4 en más de un canal, con un máximo de 3 videos distintos. Estos números anticipan la sección 10: la red estará fragmentada porque casi nadie conecta contenidos.


Categorías y consultas de recolección

Figura 4. Composición temática y de muestreo



El catalogo esta dominado por News & Politics (138/293 = 47.1%), pero los comentarios observados lo estan aun mas: la cobertura de comentarios no es proporcional al catalogo, es un submuestreo sesgado hacia unos pocos canales.

Figura 5. Consultas de recolección: catalogo frente a comentarios



Las 21 consultas del catalogo se reducen a 6 en los comentarios. La consulta '@quorumgt/videos' aporta 231 comentarios (56.9%): la cobertura de comentarios responde al procedimiento de recolección, no a la popularidad del contenido.


El catalogo esta dominado por News & Politics (138 de 293 videos, 47,1 %), seguido de People & Blogs (66) y Entertainment (48). Pero la distribución de los **comentarios** esta aun mas sesgada que la del catalogo, y en una dirección distinta: el grueso de los comentarios recolectados corresponde a videos de News & Politics de unos pocos canales. La comparación lado a lado de la figura 4 muestra que la cobertura de comentarios **no es proporcional al catalogo**: es un submuestreo concentrado, no una muestra reducida representativa.

La figura 5 lo hace explicito desde el lado del muestreo: de las 21 consultas que construyeron el catalogo, solo 6 aparecen en los comentarios, y una sola de ellas (@quorumgt/videos) aporta 231 de los 406 comentarios (56,9 %).

La estructura de participacion que se describe en las secciones siguientes esta condicionada por esa decision de recoleccion.

Hashtags

Figura 6. Hashtags: los publica el canal, no la audiencia



Los hashtags viven en el contenido publicado por los canales (588 usos) y practicamente no en los comentarios (1 usos en 1 hashtags unicos sobre 406 comentarios). El etiquetado tematico es una practica del emisor, no de la audiencia en esta muestra.


Tabla 21. Hashtags mas frecuentes en el contenido publicado por los canales

Hashtag	Frecuencia
#guatemala	48
#larondagt	29
#noticias	14
#envivodca	12
#nacionales	7
#like	7
#comenta	7
#comparte	7
#siguenos	7
#protegeryservir	6
#noticiasguatemala	6
#pnc	5

Los hashtags son una practica del **emisor**, no de la audiencia. En titulos y descripciones de video hay 588 usos de 338 hashtags distintos, mientras que en los 406 comentarios hay 1 usos de 1 hashtags. Este desequilibrio hace que los hashtags sean utiles para caracterizar el contenido publicado, pero inservibles para caracterizar la conversacion: para eso se usan las palabras y bigramas de los comentarios.


Palabras y bigramas frecuentes en los comentarios

Figura 7. 25 palabras mas frecuentes en los comentarios



Vocabulario politico-institucional: el termino mas frecuente aparece 56 veces en 10.3% de los comentarios. Ningun termino domina, lo que indica una conversacion tematicamente dispersa dentro de un mismo marco de referencia.

Figura 8. 25 bigramas mas frecuentes en los comentarios



El bigrama mas frecuente ('bernardo arevalo') aparece 10 veces. Las frecuencias bajas de los bigramas confirman que no existen consignas repetidas ni copy-paste masivo: los comentarios son redacciones individuales.

Tabla 22. 12 palabras y 12 bigramas mas frecuentes en texto_limpio

#	Palabra	Frec.	% docs	Bigrama	Frec.	% docs
1	pueblo	56	10.3%	bernardo arevalo	10	2.0%
2	guatemala	51	11.9%	presidente bernardo	9	1.8%
3	diputado	50	9.8%	ciudad guatemala	6	1.5%
4	el	46	9.3%	buscar trabajo	5	1.3%
5	pagar	39	7.6%	dar el	5	1.3%
6	dinero	34	6.8%	nery roda	5	1.3%
7	presidente	32	6.6%	pueblo pagar	5	1.3%
8	corrupto	30	5.3%	bla bla	5	0.5%
9	trabajo	29	6.8%	pagar sueldo	5	1.3%
10	seguir	23	5.6%	pacto corrupto	5	1.0%
11	excelente	22	5.3%	vivo guatemala	4	1.0%
12	sueldo	20	3.8%	diputado alcanzar	4	1.0%

El vocabulario es politico-institucional y esta encabezado por «pueblo» (56 apariciones, presente en 10.3% de los comentarios). Ningun termino domina el corpus: el mas frecuente aparece en menos de una quinta parte de los comentarios, de modo que la conversacion es tematicamente dispersa dentro de un marco de referencia comun.


Los bigramas son mas informativos que las palabras aisladas y confirman la ausencia de coordinacion: el bigrama mas frecuente («bernardo arevalo») aparece 10 veces en 406 comentarios. No hay consignas repetidas ni texto copiado en masa; cada comentario es una redaccion individual. Ese dato importa para descartar actividad automatizada como explicacion de la concentracion.

[illegible]

CC3084 Data Science · Laboratorio 6 · Analisis de redes sociales (YouTube)

5.2 Concentracion de la participacion

Figura 11. Concentracion de la participacion observada (curvas de Lorenz)



La participacion esta muy concentrada por video (Gini=0.6596) y por canal (Gini=0.6644), pero muy repartida por autor (Gini=0.1643): pocos videos reciben casi todo, y casi cada comentario proviene de una persona distinta.

Tabla 23. Concentracion de la participacion observada

Distribucion	Unidades	Gini	Top 1	Top 3	Top 5	Top 10	Unidades para el 50 %
Comentarios por video observado	19	0.6596	39.7%	63.0%	75.4%	93.6%	2 (10.5%)
Comentarios por canal	8	0.6644	63.0%	86.5%	96.1%	100.0%	1 (12.5%)
Comentarios por autor	332	0.1643	1.5%	4.2%	6.4%	10.3%	129 (38.9%)
Autores unicos por video	19	0.6402	37.3%	60.9%	73.8%	92.4%	2 (10.5%)
Visualizaciones por video (catalogo)	293	0.9493	46.3%	68.3%	73.5%	82.0%	2 (0.7%)
Videos por canal (catalogo)	97	0.5741	10.9%	26.3%	36.9%	53.9%	9 (9.3%)
«Me gusta» por comentario	406	0.8957	17.4%	40.6%	53.7%	67.2%	5 (1.2%)

La estructura de la concentracion tiene dos caras opuestas y esa oposicion es el hallazgo. **Por contenido y por emisor esta muy concentrada:** los dos videos mas comentados acumulan la mitad de los comentarios (2 unidades para el 50 %), los tres primeros 63.0% y los cinco primeros 75.4%, con un Gini de 0.6596. Por canal la concentracion es aun mayor: un solo canal reúne 63.0% de los comentarios.


Por persona, en cambio, la participacion esta casi perfectamente repartida: el Gini por autor es de solo 0.1643, el autor mas activo aporta 1.5% de los comentarios y hacen falta 129 autores (38.9% del total) para acumular la mitad. La curva de Lorenz del tercer panel de la figura 11 es casi la diagonal.

La lectura conjunta es que **la concentracion de esta muestra es de atencion, no de voz**. Unos pocos contenidos capturan casi toda la participacion, pero dentro de ellos la participacion se distribuye entre muchas personas que hablan una sola vez. No hay un grupo pequeno de usuarios dominando la conversacion; hay un grupo pequeno de videos que la concentra.

Los videos y canales que concentran la participacion

Tabla 24. Top 10 videos por comentarios observados

#	Video	Canal	Com.	Aut.	% del total	% acum.	Vistas
1	Qué rico come tu diputado	Quorum	161	128	39.7%	39.7%	11 775
2	La cooptación de Walter Mazariegos en I...	Quorum	50	49	12.3%	52.0%	10 156
3	Inician los trabajos de recuperación de...	Gobierno de la Repúbl...	45	32	11.1%	63.1%	11 670
4	Plan 2032 Ciudad de Guatemala	Municipalidad de Guat...	25	25	6.2%	69.2%	304 089
5	Conferencia de Prensa del Gobierno de G...	Gobierno de la Repúbl...	25	19	6.2%	75.4%	3 628
6	EE.UU. envía a mexicanos deportados a G...	Noticias Telemundo	25	18	6.2%	81.5%	14 200
7	Arroz con pollo a la MONOPOLIO	Quorum	16	16	3.9%	85.5%	1 954
8	Capturan a presuntos delincuentes disfr...	Noti7	14	13	3.5%	88.9%	6 692
9	Internet: escoger el menos malo	Quorum	12	10	3.0%	91.9%	717
10	Capturan a ladrón que había quedado gra...	TN23 Guatemala	7	7	1.7%	93.6%	4 616



Solo 8 de 97 canales del catalogo tienen comentarios recolectados. El canal lider aporta 256 comentarios (63.1%) distribuidos en 11 videos.


Tabla 25. Canales por participacion observada

#	Canal	Com.	% total	% acum.	Videos con com.	Videos en catalogo	Autores
1	Quorum	256	63.0%	63.0%	11	18	214
2	Gobierno de la República de Guate...	70	17.2%	80.3%	2	32	50
3	Noticias Telemundo	25	6.2%	86.5%	1	2	18
4	Municipalidad de Guatemala	25	6.2%	92.6%	1	27	25
5	Noti7	14	3.5%	96.1%	1	3	13
6	PrensaLibreOficial	7	1.7%	97.8%	1	17	7
7	TN23 Guatemala	7	1.7%	99.5%	1	7	7
8	Noticiero Guatevisión 13 Hrs.	2	0.5%	100.0%	1	2	2

El video mas comentado es «Qué rico come tu diputado» de Quorum, con 161 comentarios de 128 autores distintos (39.7% de todos los comentarios del conjunto). El canal lider es Quorum, con 256 comentarios (63.0%) repartidos en 11 videos. Conviene notar que ese canal tiene 18 videos en el catalogo: su peso en los comentarios se debe a que fue objeto de un barrido especifico de canal durante la recoleccion, no necesariamente a que genere mas conversacion que los demas.

5.3 Popularidad frente a participacion

Figura 10. Visibilidad frente a participacion observada



Con $n=19$ videos, la correlacion de rangos entre visualizaciones y comentarios observados es $\rho=0.8115$ ($p=2e-05$), significativa al 5%: una asociacion monotona fuerte y positiva. Aun asi el video mas visto (304,089 vistas) no es el mas comentado (161 comentarios con 11,775 vistas). Ambos ejes son conteos parciales y la asociacion no implica causalidad.

Tabla 26. Correlaciones entre visibilidad y participacion observada

Par de variables	n	Spearman rho	p	Pearson log-log r	Kendall tau	Signif. 5 %
Visualizaciones vs comentarios observados	19	0.8115	2e-05	0.7128	0.6208	si
Visualizaciones vs autores unicos	19	0.8118	2e-05	0.7225	0.6210	si
Comentarios vs autores unicos	19	0.9982	0.0	0.9971	0.9908	si
Visualizaciones vs «me gusta» totales	19	0.7756	0.0001	0.8191	0.6287	si

Spearman es la medida principal y Pearson solo un complemento. La razon es la forma de los datos: las visualizaciones tienen asimetria de 14.26 y los comentarios observados de 3.35, con $n = 19$. Con esa asimetria y esa n , un coeficiente de Pearson sobre los valores brutos estaria dominado por uno o dos videos; una correlacion de rangos no. Se reporta ademas Pearson sobre $\log_{10}$ de ambas variables, que es defendible porque linealiza relaciones de potencia, y Kendall tau, mas robusto aun con n pequena. Los tres coinciden en signo y magnitud.

La asociacion entre visualizaciones y comentarios observados es **fuerte, positiva y significativa**: $\rho = 0.8115$ ($p = 2e-05$). Practicamente identica para autores unicos ($\rho = 0.8118$). Y la relacion entre comentarios y autores unicos es casi perfecta ($\rho = 0.9982$), lo que vuelve a indicar que el numero de comentarios y el numero de personas son casi la misma cantidad en esta muestra.

El orden coincide, pero el detalle no. El video mas visto del conjunto observado (Plan 2032 Ciudad de Guatemala, 304 089 visualizaciones) recibio 25 comentarios observados, mientras que el mas comentado (Qué rico come tu diputado) acumula 161 comentarios con 11 775 visualizaciones, un orden de magnitud menos de audiencia. La visibilidad ordena la participacion, pero no la determina.

Tres advertencias sobre esta correlacion. Primera: correlacion no es causalidad, y aqui la direccion causal es ambigua en ambos sentidos (mas visualizaciones dan mas oportunidades de comentar, pero un video con mucha discusion tambien recibe mas recomendaciones del algoritmo). Segunda: el conteo de comentarios proviene de la muestra recolectada, no del total real de YouTube, asi que el eje vertical mide cobertura de recoleccion tanto como participacion. Tercera: las visualizaciones son un corte al momento de la recoleccion y siguen creciendo; dos videos publicados en fechas distintas no son comparables sin ajustar por antigüedad, y esa correccion no es posible con fechas relativas.

6. Preguntas obligatorias del inciso 3.5

Las seis preguntas se responden por separado y con evidencia cuantitativa. Algunas requieren resultados de las secciones 8 a 12 (redes, comunidades, centralidad y sentimiento); en esos casos se anticipa la cifra y se remite a la seccion donde se deriva.

6.1 ¿Que videos y canales concentran la mayor participacion observada?

Videos. «Qué rico come tu diputado» del canal Quorum concentra 161 comentarios de 128 autores, es decir 39.7% de todos los comentarios del conjunto. Los tres videos mas comentados suman 63.0% y los cinco primeros 75.4%. Bastan 2 videos para acumular la mitad de la participacion (Gini = 0.6596).

Canales. Quorum reúne 256 comentarios (63.0%) de 214 autores distintos, repartidos en 11 videos. Los tres primeros canales acumulan 86.5% y bastan 2 canales para el 80 % (Gini = 0.6644).

Matiz necesario. La concentracion por contenido conviene contrastarla con la del autor: el Gini por autor es de solo 0.1643. La participacion se concentra en pocos videos y pocos canales, pero se reparte entre muchisimas personas. Ademas, parte de esta concentracion es un artefacto del muestreo: el canal lider fue objeto de un barrido especifico de canal (@quorumgt/videos), lo que garantiza que aporte muchos comentarios independientemente de su volumen real de conversacion.

6.2 ¿Existen audiencias compartidas entre videos, canales o temas?

Si, pero de forma marginal. Solo 9 de 332 autores (2.71%) comentaron en mas de un video, y 4 en mas de un canal. Esos autores generan 11 de las 171 conexiones posibles entre videos (densidad 0.064327), y 9 de 19 videos quedan sin ninguna audiencia compartida observada.

Tabla 27. Magnitud de la audiencia compartida observada

Metrica	Valor
Autores totales	332
Autores que comentaron en mas de un video	9 (2.7%)
Autores que comentaron en mas de un canal	4
Aristas en la proyeccion video-video	11 de 171 posibles
Densidad de la proyeccion video-video	0.0643
Peso maximo de una arista (autores compartidos)	2
Aristas con mas de un autor compartido	2
Videos sin audiencia compartida observada	9 (47.4%)
Aristas en la proyeccion autor-autor	10 732
Componentes de la proyeccion video-video	10, 1, 1, 1, 1, 1, 1, 1, 1, 1

El contraste entre las dos proyecciones es ilustrativo. La de autores tiene 10 732 aristas, un numero enorme, pero eso no indica audiencias entrelazadas: son las cliques que la proyeccion crea mecanicamente dentro de cada video (si 128 personas comentan el mismo video, la proyeccion las une a todas entre si). La cifra que si informa sobre audiencia compartida es la de la proyeccion video-video: 11 aristas, todas de peso 1 o 2, y 9 videos sin ninguna conexion.

En cuanto a temas, la audiencia compartida se da casi enteramente **dentro** del mismo campo tematico. Las tres comunidades detectadas (seccion 11) agrupan videos de politica nacional, comunicacion de gobierno y regulacion economica; los cruces entre esos bloques son los que sostienen los 7 autores puente.

6.3 ¿Que autores funcionan como puentes entre contenidos que de otra forma permanecerian separados?

Criterio. Un autor es puente si al eliminarlo de la red bipartita aumenta el numero de componentes de la proyeccion video-video. Es una prueba de eliminacion verificada, no un ranking de grado.

De los 332 autores, 9 comentaron en mas de un video, 4 en mas de un canal, 2 en mas de una comunidad, y **7 superan la prueba de eliminacion**. Solo 9 autores (2.7%) tienen intermediacion positiva en la proyeccion autor-autor: el resto pertenece a una unica clique de video y no esta en el camino entre nada.

Tabla 28. Autores puente verificados por prueba de eliminacion

Handle	Com.	Videos	Canales	Comunidades	Δ componentes	Aristas perdidas	Canales que conecta
@hashojea7348	4	3	1	1	+1	2	Quorum
@inge_vergueta	3	3	1	2	+1	2	Quorum
@virgiliogarcia3039	3	2	2	2	+1	1	Gobierno de la República de Guatemala Quor...
@MarcosCarillo-b1r	2	2	2	1	+1	1	Quorum TN23 Guatemala
@franciscoflores3120	2	2	2	1	+1	1	Gobierno de la República de Guatemala Noti7
@moisesvaldez4043	2	2	2	1	+1	1	PrensaLibreOficial Quorum
@josegil3813	2	2	1	1	+1	1	Gobierno de la República de Guatemala

La tabla se lee asi: al retirar a ese autor de la red bipartita y recalcular la proyeccion video-video, el numero de componentes conexas **augmenta** en la cantidad indicada. Es decir, esa persona era el unico vinculo observado entre dos grupos de contenido. Es una propiedad estructural verificada, no una lectura de un ranking.

Que significa y que no significa ser «puente» aqui. Significa que esa cuenta publico comentarios observados en videos que ninguna otra cuenta recolectada comento a la vez. No significa que difunda informacion entre comunidades, ni que tenga influencia, ni que conozca a nadie. Y su condicion de puente es fragil por construccion: depende de que no se hayan recolectado otros comentarios que sostendrian la misma conexon. Con una recoleccion mas completa, es probable que varios de estos puentes dejaran de ser unicos.

6.4 ¿Que temas y sentimientos caracterizan a las principales comunidades de participacion?

Louvain ponderado sobre la proyeccion video-video devuelve 12 comunidades ($Q = 0.4053$), de las cuales 9 son singletons. Las tres no triviales, que son todas las que existen, se caracterizan así:

Tabla 29. Caracterizacion tematica y afectiva de las tres comunidades

Com.	Videos	Com. obs.	Autores	Canales	Terminos TF-IDF distintivos	% NEG	% NEU	% POS	Polaridad neta
C0	4	225	187	PrensaLibreOficial Quorum ...	diputado, pueblo, sueldo, almuerzo, corrupt...	76.0%	15.1%	8.9%	-67.1
C1	3	84	62	Gobierno de la República de G...	presidente, presidente bernardo, terminar, ...	45.2%	30.9%	23.8%	-21.4
C2	3	34	29	Quorum	empresa, internet, tigo, libre, competencia...	50.0%	20.6%	29.4%	-20.6

C0 — Critica al Congreso y a la corrupcion institucional (4 videos, 225 comentarios, 187 autores). Sus terminos distintivos son *diputado, pueblo, sueldo, almuerzo, corrupto, ganar, pagar, salario* y sus bigramas incluyen «pueblo pagar», «pagar sueldo» y «pacto corrupto». Es la comunidad mas negativa del conjunto (76.0% NEG, polaridad neta -67.1) y agrupa periodismo de investigacion con noticias de sucesos.

C1 — Comunicacion del Ejecutivo (3 videos, 84 comentarios, 62 autores). Terminos distintivos: *presidente, presidente bernardo, terminar, puente, bernardo arevalo, senor, arevalo, tren*, con «presidente bernardo» y «bernardo arevalo» como bigramas dominantes. Es la menos negativa de las tres (45.2% NEG frente a 23.8% POS, polaridad neta -21.4): conviven el apoyo explicito («apoyo presidente») con la impaciencia («bla bla»).

C2 — Regulacion economica y movilidad urbana (3 videos, 34 comentarios, 29 autores). Terminos distintivos: *empresa, internet, tigo, libre, competencia, cliente, recargar, excelente*, con «ley competencia» y «libre mercado». Es la comunidad mas pequena y la de vocabulario mas especifico; su polaridad neta es -20.6 con 29.4% de comentarios positivos, la proporcion mas alta de las tres.

La diferencia de composicion de sentimiento entre comunidades es estadisticamente significativa: chi-cuadrado = 100.3471, $gl = 8$, $p = 0.0$, V de Cramer = 0.3573, sobre las 5 comunidades con $n \geq 10$. Parte de las frecuencias esperadas es menor que 5, por lo que el valor p es aproximado.

6.5 ¿La visibilidad medida mediante visualizaciones coincide con la participacion observada?

Coinciden en el orden pero no en el detalle. Sobre los 19 videos con comentarios recolectados la correlacion de rangos es $\rho=0.8115$ ($p=2e-05$), fuerte y significativa. Sin embargo el video mas visto (304,089 vistas) recibio solo 25 comentarios observados, mientras que el mas comentado (161) tiene 11,775 vistas: la visibilidad ordena la participacion pero no la determina.

Hay que anadir dos precisiones. Primera: el Gini de visualizaciones del catalogo (0.9493) es mucho mayor que el de comentarios por video (0.6596), es decir, la visibilidad esta mas concentrada que la participacion. Segunda: los videos con comentarios recolectados no son los mas vistos del catalogo (Mann-Whitney $p = 0.20265$), de modo que la relacion observada entre visibilidad y participacion se estima sobre un subconjunto que no fue elegido por popularidad. Eso es bueno para la validez interna de la comparacion y malo para su generalizacion.

6.6 ¿Que conclusiones estan limitadas por el procedimiento de recoleccion y la cobertura de los datos?

Esta pregunta se responde en detalle en la seccion 16. En terminos de las conclusiones concretas de este informe, las mas afectadas son:

- **Cualquier afirmacion sobre volumen de participacion.** Solo 6.5% de los videos tiene comentarios recolectados y no necesariamente todos los de cada video. La frase «este video recibio 161 comentarios» debe leerse siempre como «se recolectaron 161 comentarios de este video».
- **La estructura de la red.** Una sola consulta (@quorumgt/videos) aporta 231 de los 406 comentarios. La fragmentacion medida, el numero de componentes y la identidad de los puentes son propiedades de la muestra tanto como del fenomeno.

- **Todo aislamiento.** Un video sin audiencia compartida en estos datos puede tenerla en YouTube; solo se sabe que no se observo.
- **Cualquier reconstruccion de conversacion.** El conjunto contiene unicamente comentarios principales: `reply_count` indica que hubo 51 respuestas en total, pero ninguna de ellas esta en los datos ni se sabe quien las escribio.
- **Toda comparacion temporal.** `published_text` y `published_time` son relativos y redondeados por YouTube; no hay fecha absoluta de comentario.
- **Toda cifra de popularidad o aprobacion.** `view_count`, `like_count` y `reply_count` son cortes al momento de la recoleccion, no totales finales.

7. Preguntas adicionales del inciso 3.6

Las cinco preguntas de esta seccion surgieron de hallazgos concretos del analisis exploratorio y de la red, no de una lista generica. Cada una se motiva con el hallazgo que la origina y se responde con una prueba estadistica.

7.1 ¿Los autores recurrentes participan dentro de un solo canal o atraviesan canales?

Por que surge: El EDA mostro que 46 autores publicaron mas de un comentario pero solo 9 lo hicieron en mas de un video. La pregunta es si la recurrencia es fidelidad a un canal o movilidad entre canales.

Respuesta. La recurrencia es abrumadoramente intra-video. De 46 autores con mas de un comentario, 37 (80.4%) los publicaron todos en el mismo video y 42 (91.3%) dentro de un solo canal. Solo 4 autores atraviesan canales, con un maximo de 2 canales distintos. En esta muestra 'comentar mas' significa insistir en el mismo hilo, no seguir a varios emisores.

Evidencia de la pregunta 7.1

Metrica	Valor
N autores recurrentes	46
% autores recurrentes	13.860
Recurrentes en un solo video	37
% recurrentes en un solo video	80.430
Recurrentes en un solo canal	42
% recurrentes en un solo canal	91.300
Recurrentes multicanal	4
Max canales por autor	2

7.2 ¿Los videos con mas respuestas tienen tambien mayor diversidad de autores?

Por que surge: `reply_count` no permite construir aristas, pero si mide cuanta conversacion genero cada comentario. Si mas respuestas vinieran con mas autores distintos, la conversacion seria colectiva; si no, seria un puado de hilos aislados.

Respuesta. El numero absoluto de respuestas crece con el numero de autores ($\rho=0.697$, $p=0.00092$), pero la *diversidad* relativa (autores unicos por comentario) se relaciona negativamente con el volumen ($\rho=-0.731$, $p=0.00037$): en los videos mas comentados hay proporcionalmente mas autores que repiten. Aun asi la diversidad media es 0.933, muy cerca de 1: casi cada comentario proviene de una persona distinta.

Evidencia de la pregunta 7.2

Metrica	Valor
N	19
Spearman respuestas vs autores	$\rho = 0.6965$, $p = 0.00092$, significativo
Spearman respuestas vs diversidad	$\rho = -0.6626$, $p = 0.00199$, significativo
Spearman comentarios vs diversidad	$\rho = -0.7315$, $p = 0.00037$, significativo
Total respuestas	51
Videos con respuestas	9
Diversidad media	0.933
Diversidad min	0.711

7.3 ¿Que consultas de recoleccion recuperaron contenido perteneciente a multiples comunidades, y hasta que punto la consulta determina la comunidad?

Por que surge: source_query describe el muestreo, no el tema. Si cada comunidad correspondiera exactamente a una consulta, las 'comunidades' serian un artefacto del procedimiento de recoleccion y no una estructura de audiencia.

Respuesta. De las 7 consultas que recuperaron videos con comentarios, 4 aparecen en mas de una comunidad. La concordancia entre consulta y comunidad es $NMI=0.639$ pero $ARI=0.083$. El ARI, que corrige por azar, es bajo: la particion en comunidades NO es una relectura de la consulta de recoleccion. El NMI resulta alto solo porque la particion tiene 9 singletons, y una particion muy fragmentada comparte informacion con casi cualquier etiquetado. La conclusion es que las comunidades responden a audiencia compartida y no al muestreo, aunque el muestreo determina que agrupamientos pueden llegar a observarse.

Evidencia de la pregunta 7.3

Metrica	Valor
N consultas con videos comentados	7
N consultas en varias comunidades	4
Nmi consulta vs comunidad	0.639
Ari consulta vs comunidad	0.083

7.4 ¿El sentimiento del comentario se asocia con su longitud y con los 'me gusta' que recibe?

Por que surge: El 61.6% de los comentarios se clasifico como negativo. Vale preguntar si la negatividad viene acompañada de textos mas largos (mas argumentacion) y de mas o menos aprobacion de otros usuarios.

Respuesta. Si, en las dos direcciones. Los comentarios negativos son los mas largos (mediana 132 caracteres frente a 76 de los positivos y 41 de los neutros; Kruskal-Wallis $H=73.9$, $p=0.0$), pero reciben menos aprobacion: mediana de 0 'me gusta' frente a 2 de los positivos ($H=27.6$, $p=1e-06$). La critica se argumenta mas y se premia menos en esta muestra.

Evidencia de la pregunta 7.4

Metrica	Valor
Longitud mediana por clase	NEG: 132.5, NEU: 41.0, POS: 76.0
Kruskal-wallis longitud	$H = 73.9042$, $p = 0.0$, significativo
Me gusta mediana por clase	NEG: 0.0, NEU: 1.0, POS: 2.0
Me gusta medio por clase	NEG: 1.7, NEU: 7.4, POS: 17.0
Kruskal-wallis me gusta	$H = 27.5768$, $p = 1e-06$, significativo
Spearman probpos vs me gusta	$\rho = 0.2197$, $p = 8e-06$, significativo
N por clase	NEG: 250.0, NEU: 77.0, POS: 79.0

7.5 ¿Las visualizaciones de un video predicen su posicion en la red de audiencia compartida?

Por que surge: Un video muy visto podria atraer audiencia de muchos otros contenidos y quedar central en la proyeccion video-video. Si no ocurre, el papel estructural de un video no se deduce de su popularidad.

Respuesta. No de forma significativa. Con $n=19$, la correlacion de rangos entre visualizaciones y grado en la proyeccion es $\rho=0.289$ ($p=0.2307$) y con betweenness $\rho=0.314$ ($p=0.1906$). El video mas visto de la muestra (Plan 2032 Ciudad de Guatemala, 304,089 vistas) tiene grado 0, mientras que el mas central es Qué rico come tu diputado. El numero de comentarios observados si predice el grado ($\rho=0.678$, $p=0.0014$): la posicion estructural depende de la participacion recolectada, no de la visibilidad.

Evidencia de la pregunta 7.5

Metrica	Valor
N	19
Spearman views vs degree	$\rho = 0.2887$, $p = 0.23067$, no significativo
Spearman views vs betweenness	$\rho = 0.3139$, $p = 0.19059$, no significativo
Spearman comentarios vs degree	$\rho = 0.6781$, $p = 0.00142$, significativo

8. Construcción de la red bipartita autor-video

8.1 Definición de la red

La red es **bipartita y no dirigida**. Tiene dos conjuntos de nodos que no se mezclan y toda arista cruza de un conjunto al otro:

Tabla 30. Definición formal de la red bipartita

Elemento	Definición
Nodos tipo A (autor)	Un nodo por cada <code>author_channel_id</code> distinto. 332 nodos.
Nodos tipo B (video)	Un nodo por cada <code>video_id</code> con comentarios observados. 19 nodos.
Arista	Existe entre un autor y un video si ese autor publico al menos un comentario observado en ese video. No dirigida.
Peso de la arista	Numero de comentarios observados de ese autor en ese video. Un solo par autor-video genera una arista de peso k , nunca k aristas paralelas.
Prefijo de los identificadores	A : y V : en el grafo, para que un <code>author_channel_id</code> y un <code>video_id</code> no puedan colisionar. Las tablas exportadas incluyen <code>raw_id</code> sin prefijo.

8.2 Significado preciso de una arista

Una arista autor-video significa exclusivamente que esa cuenta publico uno o mas comentarios observados en ese video, y su peso es cuantos.

No significa amistad. No significa que hubo una respuesta. No significa que hubo conversacion. No significa acuerdo con el contenido del video ni con otros comentaristas. No significa aprobacion.

La co-participacion es coincidencia en un espacio de comentarios, y nada mas. Dos personas que comentaron el mismo video pueden no haberse leído nunca, y de hecho en un video con 128 comentaristas eso es lo mas probable.

`reply_count` **no se usa en ningun momento para construir aristas**. La variable indica cuantas respuestas recibio un comentario, pero no identifica a sus autores, así que no puede sostener un vinculo entre personas. Aparece unicamente como atributo agregado de nodos y aristas. El pipeline verifica en cada corrida que la suma de pesos de la red sea igual al numero de comentarios (406) y no al numero de respuestas, lo que hace imposible haber usado la variable equivocada sin que la validacion falle.

8.3 Dimensiones e invariantes verificadas

Tabla 31. Dimensiones de la red bipartita

Metrica	Valor
Nodos totales	351
Nodos de tipo autor	332
Nodos de tipo video	19
Aristas	343
Suma de los pesos	406
Comentarios usados	406
Peso maximo de una arista	6
Aristas con peso mayor que 1	40

Tabla 32. Invariantes comprobadas automaticamente en cada ejecucion

Invariante	Resultado
La suma de los pesos es igual al numero de comentarios	CUMPLE
Hay exactamente una arista por par autor-video	CUMPLE
Todo nodo autor proviene de un author_channel_id	CUMPLE
Todo nodo video proviene de un video_id	CUMPLE
Toda arista une un autor con un video (bipartita)	CUMPLE
El grafo es no dirigido	CUMPLE
No hay bucles	CUMPLE
Todos los extremos de las aristas existen en la tabla de nodos	CUMPLE
reply_count no se uso para crear ninguna arista	CUMPLE

Las 9 invariantes se comprueban en cada corrida y el pipeline aborta si alguna falla, de modo que no es posible publicar resultados con una red mal construida. La mas importante es la primera: **la suma de los pesos (406) es exactamente igual al numero de comentarios (406)**, lo que demuestra que ningun comentario se perdio ni se conto dos veces. La segunda garantiza que hay una sola arista por par autor-video. De las 343 aristas, 40 tienen peso mayor que 1, con un maximo de 6: son los casos de autores que comentaron varias veces el mismo video.

8.4 Tablas de nodos y de aristas

Se entregan en `results/networks/bipartite_nodes.csv` (351 filas, 21 columnas) y `results/networks/bipartite_edges.csv` (343 filas, 13 columnas), y ademas en formato GraphML (`bipartite.graphml`) para poder abrirlas en Gephi. Los atributos son:

Tabla 33. Atributos de la tabla de nodos


Columna	Contenido
node_id	Identificador en el grafo, con prefijo A: o V:
raw_id	author_channel_id o video_id original, sin modificar
node_type / bipartite_set	author (0) o video (1)
display_name	Nombre del autor o titulo del video (solo etiqueta)
handle	Handle normalizado y decodificado (solo etiqueta)
channel_id / channel_name	Canal dueno del video (vacio en nodos de autor)
category / source_query / source_group	Metadatos del video
view_count	Visualizaciones del video al momento de la recoleccion
degree / strength	Grado y grado ponderado en la red bipartita
n_comentarios_observados	Comentarios del autor, o recibidos por el video
n_videos_comentados / n_canales_comentados	Amplitud de participacion del autor
n_autores_observados	Autores distintos que comentaron el video
me_gusta_recibidos / respuestas_recibidas	Agregados de interaccion
largo_medio_comentario	Longitud media de los comentarios del autor

Tabla 34. Atributos de la tabla de aristas

Columna	Contenido
source / target	Nodo autor y nodo video (el orden es convencional: la red es no dirigida)
source_type / target_type	Siempre author y video
source_raw_id / target_raw_id	Identificadores originales
weight	Numero de comentarios observados del autor en el video
significado_peso	Texto que documenta la semantica del peso en el propio archivo
me_gusta_en_esos_comentarios	Suma de «me gusta» de esos comentarios
respuestas_recibidas_en_esos_comentarios	Suma de reply_count de esos comentarios (atributo, no relacion)
comment_ids	Los comment_id que sostienen la arista, para trazabilidad
source_label / target_label	Etiquetas legibles

8.5 Visualizacion de la red completa


Figura 15. Red bipartita completa autor-video
332 autores (circulos azules) + 19 videos (cuadrados naranjas), 343 aristas, suma de pesos = 406 comentarios
 ■ Autor (332) - tamaño ~ comentarios
 ■ Video (19) - tamaño ~ autores



Red completa: no se elimino ningun nodo ni arista. La estructura dominante es de estrellas casi disjuntas (un video rodeado de autores de grado 1) unidas por unos pocos autores que comentaron en mas de un video. Una arista significa unicamente que el autor publico comentarios observados en ese video: no es amistad, respuesta, conversacion ni aprobacion.

La figura contiene la red completa: no se elimino ningun nodo ni ninguna arista. Lo que se ajusto es la presentacion (transparencia de aristas, tamaño de nodos proporcional al grado, etiquetas solo en los 19 nodos de video), pero la estructura es integra. La forma dominante es un conjunto de **estrellas casi disjuntas**: cada video aparece rodeado de una corona de autores de grado 1, y las estrellas se tocan solo a través de unos pocos autores de grado 2 o 3. Nueve de las estrellas están completamente separadas del resto.

Figura 16. Ampliación: solo los 9 autores que comentaron en mas de un video y los 10 videos que conectan



Vista ampliada COMPLEMENTARIA de la figura 15 (no la sustituye). Estos 9 autores son el unico mecanismo por el que los videos de la muestra quedan conectados entre si: el resto de autores tiene grado 1 y no aporta conexión entre contenidos.

La segunda figura es una **ampliación complementaria**, no un reemplazo: muestra solo los autores de grado mayor que 1 y los videos que conectan, para que se puedan leer las etiquetas. Deja ver con claridad que el nucleo conectado de toda la red se sostiene sobre nueve personas.

9. Proyecciones de la red

9.1 Definicion y construccion

Las dos proyecciones se obtienen con `bipartite.weighted_projected_graph` de `networkx`, cuyo peso es el numero de vecinos comunes en la red bipartita. Eso coincide exactamente con lo que pide el enunciado:

Tabla 35. Las dos proyecciones

Proyeccion	Nodos	Arista entre dos nodos si...	Peso de la arista
Autor-autor	332 autores	ambos comentaron el mismo video (al menos uno)	numero de videos compartidos
Video-video	19 videos	comparten al menos un autor	numero de autores compartidos

Una nota sobre el peso: la proyeccion **ignora deliberadamente** el peso de la red bipartita. Dos autores que coinciden en un video comparten *un* video, sin importar si uno comento una vez y el otro seis. Es la definicion del enunciado y es la correcta para lo que se quiere medir (solapamiento de participacion, no volumen).

9.2 Verificacion independiente de los pesos

Los pesos de las dos proyecciones se recalcularon desde el dataframe de comentarios, sin usar `networkx`, mediante interseccion de conjuntos (los videos de cada autor y los autores de cada video), y se compararon uno por uno:

Tabla 36. Resultado de la verificacion de pesos

Chequeo	Resultado
Aristas en la proyeccion autor-autor	10 732
Pesos incorrectos en autor-autor	0
Aristas en la proyeccion video-video	11
Pesos incorrectos en video-video	0
Peso maximo en autor-autor	2
Peso maximo en video-video	2
Existe una clique por cada video observado	si

Los 10 732 pesos de la proyeccion de autores y los 11 de la de videos coinciden con el recalclo independiente. El chequeo de cliques confirma la propiedad estructural esperada: la audiencia de cada video forma un subgrafo completo en la proyeccion de autores.

9.3 Que fenomeno representa cada proyeccion

Tabla 37. Comparacion de las dos proyecciones

Dimension	Autor-autor	Video-video
Nodos	332	19
Aristas	10 732	11
Densidad	0.1953	0.0643
Grado medio	64.65	1.16
Transitividad	0.9840	0.3158
Componentes	10	10
Nodos aislados	4	9
Fenomeno que representa	Co-participacion de audiencias dentro de un video	Solapamiento de audiencia entre contenidos
Que NO representa	Amistad, conversacion, interaccion directa ni acuerdo	Similitud tematica ni relacion editorial entre los videos


La diferencia de escala es engañosa si se lee sin cuidado. La proyeccion de autores tiene 10 732 aristas y una transitividad de 0.984, valores que sugieren una red densamente entrelazada. **No lo es**. Esa densidad es un artefacto mecanico de la proyeccion: si 128 personas comentan el mismo video, la proyeccion las une a todas entre si y genera 8 128 aristas de un solo golpe, con transitividad 1 dentro de ese bloque. Lo que la proyeccion de autores

mide, entonces, es *que tan grandes son las audiencias*, no que tan conectadas estan las personas.

La proyeccion de videos es la que informa sobre audiencia compartida real, y su lectura es la opuesta: 11 aristas sobre 171 posibles, densidad 0.0643, 9 videos aislados y pesos que solo llegan a 2. El solapamiento de publico entre contenidos es minimo.

9.4 Visualizacion de las dos proyecciones completas


Figura 17. Proyeccion autor-autor completa
332 autores, 10732 aristas (peso = numero de videos compartidos)



Red completa. Los 10732 vinculos forman una clique por cada video observado: cada bloque denso es la audiencia de un video, no un grupo de amigos. Los 9 autores resaltados son los unicos que pertenecen a mas de un bloque y por tanto los unicos que pueden unir audiencias distintas.

La proyeccion de autores se dispuso con un trazado construido a partir de su estructura conocida (un disco por audiencia de video, y los autores multivideo en un anillo interior) porque un trazado de fuerzas colapsa las 10 732 aristas de clique en una mancha ilegible. **No se elimino ningun nodo ni arista:** solo cambia la asignacion de coordenadas. Cada disco es la audiencia de un video; los nueve nodos amarillos del centro son los unicos autores que pertenecen a mas de un disco.

Figura 18. Proyeccion video-video completa
19 videos, 11 aristas (peso = autores compartidos); 9 videos aislados en gris



Red completa, incluidos los 9 videos aislados. El numero sobre cada arista es el numero de autores compartidos. Los pesos son 1 o 2: la audiencia comun entre videos es minima. Un video aislado lo esta EN LA MUESTRA, no necesariamente en YouTube.

Tabla 38. Todas las aristas de la proyeccion video-video

Video A	Video B	Autores compartidos
La cooptación de Walter Mazariegos en l...	Qué rico come tu diputado	2
Internet: escoger el menos malo	Arroz con pollo a la MONOPOLIO	2
Capturan a presuntos delincuentes disfr...	Inician los trabajos de recuperación de...	1
Inician los trabajos de recuperación de...	Conferencia de Prensa del Gobierno de G...	1
Conferencia de Prensa del Gobierno de G...	Qué rico come tu diputado	1
Caminar en una ciudad hecha para carros	Internet: escoger el menos malo	1
Caminar en una ciudad hecha para carros	Arroz con pollo a la MONOPOLIO	1
Bloqueos en Guatemala este 31 de agosto...	Qué rico come tu diputado	1
Capturan a ladrón que había quedado gra...	La cooptación de Walter Mazariegos en l...	1
La cooptación de Walter Mazariegos en l...	Internet: escoger el menos malo	1
Qué rico come tu diputado	Internet: escoger el menos malo	1

La proyeccion de videos cabe entera en una tabla: son 11 aristas. Dos de ellas tienen peso 2 y el resto peso 1, es decir, **la mayoría de las conexiones entre contenidos las sostiene una sola persona**. Los 9 videos en gris de la figura no tienen ninguna conexion; se muestran igual, separados por una linea, porque su ausencia de vinculos es un resultado y no un motivo para excluirlos.

10. Topología y fragmentación

10.1 Métricas estructurales de las tres redes

Tabla 39. Métricas topológicas comparadas

Métrica	Bipartita autor-video	Proy. autor-autor	Proy. video-video
Tipo de red	bipartita	unimodal	unimodal
Nodos	351	332	19
Aristas	343	10 732	11
Suma de pesos	406	10 734	13
Densidad	0.00558	0.19532	0.06433
Grado medio	1.954	64.651	1.158
Grado mediano	1	48	1
Grado máximo	128	183	4
Fuerza media	2.313	64.663	1.368
Fuerza máxima	161	184	5
Componentes conexas	10	10	10
Tamaño de la componente mayor	286	276	10
% de nodos en la componente mayor	81.48	83.13	52.63
Nodos aislados	0	4	9
Transitividad global	0.000000	0.984025	0.315789
Clustering medio	0.000000	0.972049	0.149123
Clustering medio ponderado	0.000000	0.486240	0.093941
Asortatividad de grado	-0.4283	0.9166	-0.0621
Diámetro (componente mayor)	12	6	5
Longitud media de camino (comp. mayor)	4.7152	2.3565	2.4889
κ global (cohesion)	0	0	0
κ en la componente mayor	1	1	1
Densidad bipartita ($ A \cdot B $)	0.05437	no aplica	no aplica
Clustering bipartito de Latapy	0.8920	no aplica	no aplica

Densidad: por que la bipartita necesita su propia formula

La densidad estandar de un grafo compara las aristas observadas con $n(n-1)/2$, que es el máximo en un grafo simple. **En una red bipartita ese máximo es imposible de alcanzar** porque no puede haber aristas dentro de un mismo conjunto: el máximo real es $|A| \cdot |B| = 332 \cdot 19 = 6\,308$. Por eso la densidad estandar de 0.00558 subestima gravemente la conectividad, y la cifra correcta es la densidad bipartita de 0.05437. Aun así es baja: se materializa poco más del 5 % de los emparejamientos autor-video posibles.

Transitividad: cero por construcción en la bipartita

La transitividad global de la red bipartita es exactamente 0.0, y eso **no es un hallazgo empírico sino una propiedad matemática**: un triángulo exige tres nodos mutuamente adyacentes, y en una red bipartita toda arista cruza de un conjunto al otro, así que el tercer vértice nunca puede cerrarse. Reportar ese cero como «falta de cohesión local» sería un error de interpretación.

La métrica interpretable para una red bipartita es el **clustering bipartito de Latapy**, que mide el solapamiento de vecindarios en lugar de triángulos. Su valor medio es 0.8920, un valor alto: los autores que comparten un video tienden a compartir también su vecindario completo, que es exactamente lo que se espera de una estructura de estrellas.

En las proyecciones la transitividad sí es informativa. La de autores tiene 0.9840, prácticamente 1, porque esta compuesta de cliques. La de videos tiene 0.3158: hay algunos triángulos de videos que comparten audiencia entre

si, pero la mayoría de las conexiones son cadenas abiertas.

10.2 Cohesion: definicion operacional

Definicion. En este informe *cohesion* significa **conectividad por nodos (κ)**: el numero minimo de nodos que hay que eliminar para desconectar el grafo. Si el grafo ya esta desconectado, $\kappa = 0$ por definicion. Como las tres redes lo estan, se reporta ademas κ calculada **sobre la componente conexas mayor**, que es la cifra interpretable en una red fragmentada, junto con la conectividad por aristas (teorema de Menger) y el clustering medio como medida de cohesion local.

Tabla 40. Medidas de cohesion de las tres redes


Medida	Bipartita	Proy. autor-autor	Proy. video-video
Grafo conexo	no	no	no
κ global (conectividad por nodos)	0	0	0
κ en la componente mayor	1	1	1
Conectividad por aristas en la componente mayor	1	5	1
Puntos de articulacion en la componente mayor	17	7	5
Puentes (aristas) en la componente mayor	279	0	5
Clustering medio (cohesion local)	0.0000	0.9720	0.1491
Diametro de la componente mayor	12	6	5
Longitud media de camino en la componente mayor	4.715	2.357	2.489

La cohesion es minima en las tres redes. κ global es 0 porque ninguna es conexas, y κ en la componente mayor es 1 en las tres: existe **un solo nodo** cuya eliminacion parte la componente principal. La componente mayor de la bipartita tiene 17 nodos con esa propiedad, la de autores 7 y la de videos 5.

Un contraste ilustrativo: en la proyeccion de autores, κ por nodos es 1 pero la conectividad por aristas es 5. Es decir, hay que cortar cinco vinculos para partirla, pero basta retirar a una persona. Esa asimetria es la firma de una red sostenida por individuos concretos y no por una malla redundante de relaciones.


10.3 Distribucion de grados

Figura 19. Distribucion de grados y de fuerza




Distribucion muy asimetrica: mediana 1 frente a maximo 3, y 99.4% de los nodos con grado <= 2. La conectividad no esta repartida: se concentra en unos pocos nodos.

Figura 20. Distribucion de grados y de fuerza



Distribucion muy asimetrica: mediana 48 frente a maximo 183, y 2.7% de los nodos con grado <= 2. La conectividad no esta repartida: se concentra en unos pocos nodos.

Figura 21. Distribucion de grados y de fuerza



Distribucion muy asimetrica: mediana 1 frente a maximo 4, y 84.2% de los nodos con grado <= 2. La conectividad no esta repartida: se concentra en unos pocos nodos.

Tabla 41. Distribucion de grados: mediana frente a maximo

Red	Grado medio	Mediana	p75	p90	p99	Max	Gini del grado	% con grado 1	% con grado ≤ 2
Bipartita	1.95	1	1	1	22.0	128	0.4784	93.2%	95.4%
Proy. autor-autor	64.65	48	127	127	131.1	183	0.4303	0.6%	2.7%
Proy. video-video	1.16	1	2	3	4.0	4	0.6124	15.8%	84.2%

El promedio de la red bipartita miente. Su grado medio es 1.95, un numero que sugiere que un nodo tipico tiene dos vecinos. La mediana es 1 y el 93.2% de los nodos tiene grado exactamente 1, mientras que el maximo es 128. La media esta arrastrada por los nodos de video, que tienen un grado promedio de 18.1 frente a 1.03 de los autores. Por eso el histograma y la ECDF de la figura 19 son necesarios: muestran una distribucion en L, no una campana.

La respuesta a la pregunta del inciso 6.1 («¿la mayoría tiene pocas conexiones o estan concentradas en unos pocos?») es inequivoca: **estan concentradas**. El Gini del grado en la bipartita es 0.4784 y en la proyeccion de videos 0.6124. La asortatividad de grado de la bipartita es -0.4283, claramente negativa, lo que confirma la estructura de estrella: los nodos de grado alto (videos) se conectan con nodos de grado bajo (autores de un solo comentario), no entre si.

En la proyeccion de autores el patron se invierte: la asortatividad es 0.9166, fuertemente positiva. Tambien es un artefacto de las cliques: todos los miembros de la audiencia de un video tienen el mismo grado, asi que se conectan con nodos de grado identico al propio.

10.4 Fragmentacion, nodos perifericos y aislados

Tabla 42. Componentes conexas de las tres redes

Red	N.º de componentes	Tamano de la mayor	% de nodos en la mayor	Tamanos de todas las componentes
Bipartita	10	286	81.5%	286, 26, 19, 5, 4, 3, 2, 2, 2, 2
Proy. autor-autor	10	276	83.1%	276, 25, 18, 4, 3, 2, 1, 1, 1, 1
Proy. video-video	10	10	52.6%	10, 1, 1, 1, 1, 1, 1, 1, 1, 1

Las tres redes tienen el mismo número de componentes (10), y no es coincidencia: la partición en componentes de la bipartita determina la de sus proyecciones. La componente mayor de la bipartita reúne 286 nodos (81.5%), y las nueve restantes son estrellas aisladas de entre 2 y 26 nodos, es decir, videos cuya audiencia recolectada no coincide con la de ningún otro video de la muestra.

Tabla 43. Nodos periféricos y aislados

Metrica	Valor
Autores con grado 1 en la bipartita (comentaron un solo video)	323 (97.3%)
Videos aislados en la proyección video-video	9 (47.4%)
Autores aislados en la proyección autor-autor	4
Componentes pequeñas (≤ 5 nodos) en la proyección de autores	7
Nodos aislados en la bipartita	0

Los 4 autores aislados en la proyección de autores son un caso interesante: son personas que comentaron un video del que **son el único comentarista recolectado**, de modo que no comparten audiencia con nadie. En la bipartita no están aislados (tienen su arista al video); en la proyección sí.

Tabla 44. Videos sin audiencia compartida observada

Video	Canal	Comentarios obs.	Autores obs.
EE.UU. envía a mexicanos deportados a Guate...	Noticias Telemundo	25	18
Plan 2032 Ciudad de Guatemala	Municipalidad de Guatem...	25	25
I'x K'at: el primer equipo guatemalteco de ...	Quorum	4	4
10 Preguntas a un año del Paro Nacional	Quorum	3	3
Noticiero en Directo 1 pm, 28 de Agosto de ...	Noticiero Guatevisión 1...	2	2
SHAI WA: la vecina queer de Casa Presidenci...	Quorum	1	1
Cruzando la ciudad a puro Transmetro	Quorum	1	1
¿Quiénes pagan más en Centroamérica?	Quorum	1	1
Edén por Salud: empleo inclusivo para perso...	Quorum	1	1

Aislamiento observado no es aislamiento real. Un nodo aislado en estas redes está aislado EN LOS DATOS OBSERVADOS, no en YouTube. Solo se recolectaron comentarios de 19 videos y no necesariamente todos los comentarios de cada uno, así que la ausencia de un vínculo puede deberse a la cobertura del muestreo y no a la ausencia de audiencia compartida real.

El caso más claro de la tabla 44 es «Plan 2032 Ciudad de Guatemala»: tiene 25 comentarios de 25 autores distintos y 304 089 visualizaciones, es el video más visto de toda la muestra, y sin embargo aparece completamente aislado. La razón no es que su público sea ajeno al resto: es que ninguno de esos 25 autores aparece también en otro de los 19 videos con comentarios recolectados. Con 274 videos sin comentarios recolectados, la probabilidad de detectar solapamiento es estructuralmente baja.

10.5 Interpretación de los hallazgos estructurales

Los números de esta sección apuntan todos en la misma dirección y admiten una lectura única. **La participación observada en YouTube no forma una comunidad conversacional: forma un conjunto de audiencias paralelas.**

- **No hay red conversacional porque no hay reincidencia.** El 93.2% de los nodos tiene grado 1, y de los 332 autores solo 9 comentaron en más de un video. Sin reincidencia entre contenidos no puede existir una estructura de red rica: la topología está determinada por ese hecho.
- **La estructura de estrella es el hallazgo, no un defecto.** Asortatividad -0.428, transitividad 0 y clustering bipartito 0.892 describen consistentemente videos-hub rodeados de comentaristas de una sola aparición. Es como se ve el consumo de contenido, no la sociabilidad.

- **La red es extremadamente fragil.** $\kappa = 1$ en la componente mayor de las tres redes y 17 puntos de articulacion en la bipartita significan que la conectividad depende de individuos concretos. En una red social robusta habria caminos redundantes; aqui la eliminacion de una persona parte el grafo.
- **La fragmentacion es en parte real y en parte de muestreo, y hay que separarlas.** Es real que la mayoría de la gente comenta un solo video: eso se observa directamente. Es de muestreo que 9 de 19 videos aparezcan aislados: con cobertura de comentarios en 274 videos mas, muchas de esas conexiones podrian materializarse.
- **El diametro de 12 y la longitud media de camino de 4.72 en la bipartita describen una cadena larga, no un mundo pequeno.** En redes sociales densas la longitud media de camino es de 4 a 6 con millones de nodos; aqui es casi 5 con 286. La informacion, si circulara por estos vinculos, tendria que recorrer muchos pasos.

11. Comunidades

11.1 Eleccion de la red y justificacion

La deteccion de comunidades se hace sobre la proyeccion video-video ponderada. Las tres razones son:

- **Es la unica red cuyas comunidades tienen una interpretacion sustantiva.** Una comunidad en esta red es un grupo de videos que comparten publico, y puede caracterizarse simultaneamente por titulo, canal, categoria, consulta de recoleccion, palabras de sus comentarios y distribucion de sentimiento.
- **La red bipartita no admite modularidad estandar.** La formulacion clasica de modularidad compara las aristas dentro de una comunidad con las esperadas bajo un modelo de configuracion que asume que cualquier par de nodos puede conectarse. En una red bipartita eso es falso, y aplicar la formula sin adaptarla produce un numero sin significado.
- **Las comunidades de la proyeccion autor-autor no aportan informacion nueva.** Esto no se afirma por intuicion: se comprobo. Ver el contraste mas abajo.

Tabla 45. Comprobacion de que las comunidades de autores son triviales

Metrica	Valor	Lectura
Comunidades de Louvain en la proyeccion autor-autor	14	—
Grupos de la etiqueta trivial «en que video comento»	19	—
NMI entre ambas particiones	0.9005	Muy alto
ARI entre ambas particiones	0.8869	Muy alto (corregido por azar)
Modularidad ponderada de la particion de autores	0.3949	—

Con $NMI = 0.900$ y $ARI = 0.887$ respecto de la etiqueta trivial «en que video comento este autor», las comunidades de la proyeccion de autores son esencialmente una relectura de la particion por video. Es lo esperado, porque la proyeccion crea una clique por video: Louvain no puede sino recuperarlas. Se reportan de todos modos como analisis complementario, pero el analisis principal es el de la proyeccion de videos.

11.2 Algoritmo, supuestos y tratamiento de los pesos

Tabla 46. Configuracion del algoritmo de comunidades

Parametro	Valor
Algoritmo	Louvain (networkx.algorithms.community.louvain_communities)
Libreria y version	networkx 3.6.1
Atributo de peso	weight = autores compartidos
Resolucion	1.0
Semilla	42

Supuestos de Louvain que conviene tener presentes. Optimiza modularidad mediante agregacion voraz en dos fases, lo que implica: (a) las comunidades son **no solapadas**, cada video pertenece a exactamente una, supuesto discutible para audiencias que podrian solaparse; (b) el resultado depende del orden de recorrido, por lo que la semilla se fija en 42; (c) sufre el **limite de resolucion**, es decir, no detecta comunidades sustancialmente menores que $\sqrt{(2m)}$, lo que en una red de 11 aristas es una limitacion severa; (d) la modularidad tiene un maximo alto por azar en redes dispersas, así que su valor absoluto no debe leerse como evidencia de estructura fuerte.

Tratamiento de los pesos. El peso de la proyeccion video-video es el numero de autores compartidos, es decir, una **intensidad**: mas peso significa vinculo mas fuerte. Esa es precisamente la semantica que la modularidad ponderada espera, así que el peso se pasa directamente sin transformar. (En el analisis de centralidad de la seccion 12 la situacion es distinta y si requiere invertirlo.) Se reportan las dos modularidades: ponderada $Q = 0.4053$ y no ponderada $Q = 0.3760$.

11.3 Resultado: numero, tamanos y calidad

Tabla 47. Resultado de la deteccion de comunidades

Metrica	Proy. video-video (principal)	Proy. autor-autor (complementaria)
Comunidades detectadas	12	14
Tamanos	4, 3, 3, 1, 1, 1, 1, 1, 1, 1, 1, 1	126, 61, 55, 28, 25, 18, 6, 4, 3, 2, 1, 1, 1, 1
Modularidad ponderada	0.4053	0.3949
Modularidad no ponderada	0.3760	0.3947
Comunidades singleton	9	4
% de nodos en singletons	47.4%	1.2%
Comunidades no triviales (> 1 nodo)	3	10
Comunidad mayor	4	126
Tamano medio	1.58	23.71

Los 9 singletons se reportan explícitamente y no se descartan. Representan el 47.4% de los videos: contenidos cuya audiencia recolectada no coincide con la de ningun otro video de la muestra. Ocultarlos inflaria artificialmente la cobertura de las comunidades «reales», que es del 52.6%. Aparecen en la figura 22, en la tabla 49 y en `results/tables/community_summary.csv`.

Robustez de la particion


Tabla 48. Comparacion con otros algoritmos de deteccion

Algoritmo	Comunidades	Tamanos	Q ponderada	NMI con Louvain
Louvain (principal)	12	4, 3, 3, 1, 1, 1, 1, 1, 1, 1, 1, 1	0.4053	1.0 (referencia)
Greedy modularity (CNM)	12	4, 3, 3, 1, 1, 1, 1, 1, 1, 1, 1, 1	0.4053	1.0000
Label propagation asincrona	11	8, 2, 1, 1, 1, 1, 1, 1, 1, 1, 1, 1	no aplica	0.8813
Componentes conexas (referencia estructural)	10	10, 1, 1, 1, 1, 1, 1, 1, 1, 1, 1, 1	no aplica	—

Louvain y greedy modularity devuelven **exactamente la misma particion** ($NMI = 1.00$), y label propagation coincide en gran medida ($NMI = 0.8813$), diferenciandose solo en que fusiona la componente conexa entera en un unico grupo. La coincidencia entre dos algoritmos independientes indica que la particion no es un artefacto de Louvain. La comparacion con las componentes conexas es igual de informativa: la componente mayor de 10 videos se subdivide en tres comunidades, de modo que Louvain **si** encuentra estructura interna y no se limita a devolver las componentes.

11.4 Visualizacion de todas las comunidades

Figura 22. Todas las comunidades de la proyeccion video-video
Louvain ponderado (semilla 42, resolucio n 1.0): 12 comunidades, modularidad ponderada Q = 0.4053, 9 singletons



Se muestran las 12 comunidades, incluidos los 9 singletons (videos sin audiencia compartida observada). $Q = 0.4053$ indica una particion mejor que el azar, pero sobre una red muy dispersa: la modularidad de un grafo casi desconectado se obtiene facilmente y no debe leerse como comunidades tematicas robustas.

Figura 23. Tamano frente a intensidad de las comunidades



El tamaño de una comunidad en numero de videos no predice su intensidad de participación: la comunidad con mas comentarios (225) tiene 4 videos, mientras que otras con mas videos acumulan mucho menos.

La figura 22 muestra las 12 comunidades, singletons incluidos, con el numero de autores compartidos sobre cada arista. La figura 23 contrasta tamaño con intensidad y revela que **no son la misma cosa**: la comunidad con mas videos (4) es también la de mas comentarios (225), pero varias comunidades singleton acumulan mas comentarios que C2, que tiene tres videos.

11.5 Caracterizacion de las tres comunidades principales

Se analizan en detalle las tres comunidades no triviales, que son todas las que existen: las nueve restantes son singletons (videos sin audiencia compartida observada) y se reportan pero no admiten una caracterizacion de comunidad.

Comunidad C0

Tabla 49. Perfil completo de C0

Dimension	Valor
Videos	4
Titulos	Bloqueos en Guatemala este 31 de agosto por alza en combustibles afectan rutas principales Capturan a ladrón que había quedado grabado mientras robaba en una parroquia de Retalhuleu La cooptación de Walter Mazariegos en la USAC Qué rico come tu diputado
Canales	3 — PrensaLibreOficial Quorum TN23 Guatemala
Categorías de YouTube	News & Politics
Consultas de recolección	@quorumgt Quorum GT guatemala noticias
Comentarios observados	225 (55.4% del total)
Autores únicos	187
Autores en más de un video de la comunidad	4
Intensidad: comentarios por video	56.25
Intensidad: comentarios por autor	1.203
«Me gusta» acumulados / medianos	450 / 1
Respuestas acumuladas	5
Visualizaciones totales / medianas	32 016 / 7 812
Aristas internas / peso interno	3 / 4
Densidad interna	0.5000
Longitud mediana del comentario	102 caracteres
Terminos distintivos (TF-IDF de los comentarios)	diputado, pueblo, sueldo, almuerzo, corrupto, ganar, pagar, salario, comida, gasto
Keywords y titulos distintivos (TF-IDF del contenido publicado)	usac, noticias guatemala, mazariegos, noticias, combustibles, walter mazariegos
Palabras mas frecuentes	pueblo (54), diputado (50), pagar (35), el (31), dinero (28), corrupto (26), trabajo (23), sueldo (20)
Bigramas mas frecuentes	nery roda (5), pueblo pagar (5), pagar sueldo (5), pacto corrupto (5), diputado alcanzar (4), buscar trabajo (4)
Hashtags en los comentarios	ninguno
Sentimiento	NEG 76.0% · NEU 15.1% · POS 8.9% (n = 225, polaridad neta -67.1, confianza media 0.827)
Comparable estadísticamente (n ≥ 10)	si

Comunidad C1

Tabla 50. Perfil completo de C1

Dimension	Valor
Videos	3
Títulos	Capturan a presuntos delincuentes disfrazados de mujer señalados de cometer asalto Conferencia de Prensa del Gobierno de Guatemala. #LaRondaGt Inician los trabajos de recuperación del Puente Belice II.
Canales	2 — Gobierno de la República de Guatemala Noti7
Categorías de YouTube	Entertainment News & Politics
Consultas de recolección	@GobiernodeGuatemala Gobierno de la República de Guatemala guatemala noticias
Comentarios observados	84 (20.7% del total)
Autores únicos	62
Autores en más de un video de la comunidad	2
Intensidad: comentarios por video	28.00
Intensidad: comentarios por autor	1.355
«Me gusta» acumulados / medianos	122 / 1
Respuestas acumuladas	16
Visualizaciones totales / medianas	21 990 / 6 692
Aristas internas / peso interno	2 / 2
Densidad interna	0.6667
Longitud mediana del comentario	86 caracteres
Terminos distintivos (TF-IDF de los comentarios)	presidente, presidente bernardo, terminar, puente, bernardo arevalo, señor, arevalo, tren, señor presidente, salvador
Keywords y títulos distintivos (TF-IDF del contenido publicado)	disfrazados, noticias, del, de, belice, belice ii
Palabras más frecuentes	presidente (27), guatemala (16), arevalo (12), proyecto (9), ano (9), bernardo (9), gobierno (9), terminar (9)
Bigramas más frecuentes	presidente bernardo (9), bernardo arevalo (9), señor presidente (4), bla bla (4), apoyo presidente (3), tren maya (3)
Hashtags en los comentarios	ninguno
Sentimiento	NEG 45.2% · NEU 30.9% · POS 23.8% (n = 84, polaridad neta -21.4, confianza media 0.764)
Comparable estadísticamente (n ≥ 10)	si

Comunidad C2

Tabla 51. Perfil completo de C2

Dimension	Valor
Videos	3
Titulos	Arroz con pollo a la MONOPOLIO Caminar en una ciudad hecha para carros Internet: escoger el menos malo
Canales	1 — Quorum
Categorias de YouTube	News & Politics
Consultas de recoleccion	@quorumgt/videos
Comentarios observados	34 (8.4% del total)
Autores unicos	29
Autores en mas de un video de la comunidad	2
Intensidad: comentarios por video	11.33
Intensidad: comentarios por autor	1.172
«Me gusta» acumulados / medianos	17 / 0
Respuestas acumuladas	1
Visualizaciones totales / medianas	3 093 / 717
Aristas internas / peso interno	3 / 4
Densidad interna	1.0000
Longitud mediana del comentario	128 caracteres
Terminos distintivos (TF-IDF de los comentarios)	empresa, internet, tigo, libre, competencia, cliente, recargar, excelente, servicio, informacion
Keywords y titulos distintivos (TF-IDF del contenido publicado)	internet, arroz, caminar, arroz con, telefonía, telefonía caminar
Palabras mas frecuentes	excelente (11), empresa (9), internet (7), ley (7), video (5), informacion (5), seguir (5), servicio (5)
Bigramas mas frecuentes	ley competencia (3), libre mercado (3), competencia seguir (2), asignado paquete (2), dar el (2), ley libre (2)
Hashtags en los comentarios	ineptobran(1)
Sentimiento	NEG 50.0% · NEU 20.6% · POS 29.4% (n = 34, polaridad neta -20.6, confianza media 0.836)
Comparable estadisticamente (n ≥ 10)	si

Lectura conjunta de las tres comunidades

Las tres comunidades se ordenan a lo largo de un eje reconocible: **la relacion del comentarista con el poder institucional**. C0 agrupa contenido que fiscaliza al Congreso y a la justicia, y es la mas negativa; C1 agrupa la comunicacion directa del Ejecutivo y es la mas mixta, con apoyo explicito conviviendo con impaciencia; C2 agrupa contenido sobre regulacion economica y movilidad urbana, temas donde la critica se dirige a empresas mas que a funcionarios, y es la de mayor proporcion de comentarios positivos.

La etiqueta tematica de cada comunidad se sostiene en evidencia convergente y no en una impresion: los terminos TF-IDF de los comentarios, los bigramas, las keywords del contenido publicado y los titulos de los videos apuntan al mismo campo semantico en los tres casos. Cuando esa convergencia no existe, la etiqueta no se pone: los nueve singletons se describen por su contenido individual, sin asignarles un tema de comunidad que no puede sostenerse con un solo video.

11.6 Las comunidades singleton

Tabla 52. Los nueve videos que forman comunidades de un solo elemento

Com.	Video	Canal	Com. obs.	Autores	% NEG	% NEU	% POS
C5	EE.UU. envía a mexicanos deportados a...	Noticias Telemundo	25	18	72.0%	20.0%	8.0%
C9	Plan 2032 Ciudad de Guatemala	Municipalidad de Guat...	25	25	8.0%	12.0%	80.0%
C6	I'x K'at: el primer equipo guatemalte...	Quorum	4	4	25.0%	0.0%	75.0%
C4	10 Preguntas a un año del Paro Nacion...	Quorum	3	3	33.3%	0.0%	66.7%
C3	Noticiero en Directo 1 pm, 28 de Agos...	Noticiero Guatevisión...	2	2	50.0%	50.0%	0.0%
C7	SHAI WA: la vecina queer de Casa Pres...	Quorum	1	1	0.0%	0.0%	100.0%
C8	Cruzando la ciudad a puro Transmetro	Quorum	1	1	100.0%	0.0%	0.0%
C10	¿Quiénes pagan más en Centroamérica?	Quorum	1	1	0.0%	0.0%	100.0%
C11	Edén por Salud: empleo inclusivo para...	Quorum	1	1	0.0%	100.0%	0.0%

Dos de estos singletons son notables. **«Plan 2032 Ciudad de Guatemala»** (25 comentarios, 25 autores) es el video mas visto de toda la muestra y el unico con polaridad claramente positiva; su aislamiento estructural conviviendo con su altísima visibilidad es la mejor ilustración de que la posición en la red no se deriva de la popularidad. **«EE.UU. envía a mexicanos deportados a Guatemala»** (25 comentarios, 18 autores, canal Noticias Telemundo) es el unico contenido de un medio internacional y tambien queda aislado, lo que es consistente con que su audiencia sea distinta de la del resto del corpus.

12. Nodos centrales y participantes puente

12.1 Medidas elegidas y por que

Tabla 53. Medidas de centralidad calculadas y su justificacion


Medida	Que mide y por que se usa aqui
Grado	Numero de vecinos: alcance directo dentro de la red.
Fuerza (grado ponderado)	Grado ponderado: intensidad total del vinculo, no solo su numero.
Betweenness	Fraccion de caminos mas cortos que pasan por el nodo. Es la medida pertinente para 'puente' porque premia estar entre grupos, no tener muchos vecinos. Se calcula con $distance = 1/weight$.
Closeness (Wasserman-Faust)	Cercania con correccion de Wasserman-Faust, necesaria porque las redes estan desconectadas y la formula clasica seria indefinida.
Harmonic centrality	Suma de reciprocos de distancias: bien definida con distancias infinitas, por lo que es la alternativa robusta a closeness en grafos fragmentados.
PageRank	Prestigio recursivo ponderado: un nodo importa si esta vinculado a nodos importantes. $\alpha = 0.85$.
Eigenvector	Version espectral del prestigio; se reporta para contrastar con PageRank, del que suele diferir en grafos desconectados.
Numero de k-core	Profundidad del nodo en la jerarquia de nucleos: perifericidad.
Puntos de articulacion	Nodos cuya eliminacion aumenta el numero de componentes. Es una propiedad estructural verificable, no un ranking.

El punto tecnico que decide si los resultados son correctos o no. En las proyecciones weight es intensidad (mas compartido = mas fuerte) pero networkx trata weight como distancia en los algoritmos de camino mas corto. Se define $distance = 1/weight$ para que un vinculo fuerte cuente como cercano.

Concretamente: dos videos que comparten 2 autores estan **mas** relacionados que dos que comparten 1, pero si se le pasa $weight=2$ a un algoritmo de camino mas corto, el algoritmo entiende que estan al **doblo de distancia**. El resultado seria el inverso del correcto. Por eso se construye $distance = 1/weight$ y esa es la que se usa en betweenness, closeness y harmonic; el peso sin transformar se usa en fuerza, PageRank y eigenvector, donde la semantica de intensidad es la correcta.

Tratamiento de los grafos desconectados. Las tres redes tienen 10 componentes, lo que rompe la definicion clasica de closeness (la distancia a un nodo inalcanzable es infinita y su inverso indefinido). Se resolvio de tres formas complementarias: betweenness de networkx suma por componente de manera nativa; closeness se calcula con la correccion de Wasserman-Faust ($wf_improved=True$), que escala por el tamaño de la componente alcanzable; y se agrega harmonic centrality, que suma reciprocos de distancias y por tanto esta bien definida con distancias infinitas. Cada nodo lleva ademas su identificador de componente y el tamaño de esta, para que ningun ranking se lea entre componentes distintas sin advertirlo.

Figura 25. Concordancia entre medidas de centralidad




Correlacion de rangos entre medidas. Grado, fuerza, PageRank y eigenvector miden casi lo mismo en estas redes, mientras que betweenness se separa: identifica una propiedad distinta (estar en el camino entre grupos) y es la medida pertinente para detectar puentes.

La matriz de correlacion de rangos justifica calcular varias medidas en lugar de una. Grado, fuerza, PageRank y eigenvector correlacionan casi perfectamente entre si: en estas redes miden lo mismo, y usar una u otra no cambia el ranking. **Betweenness se separa claramente del bloque**, lo que confirma que captura una propiedad distinta —estar en el camino entre grupos— y que es la medida pertinente para identificar puentes. Es la evidencia de por que un ranking de grado no basta para llamar «puente» a un nodo.

12.2 Autores: recurrencia, diversidad e intermediacion

Figura 24. Centralidades de autores y videos



Solo 9 de 332 autores tienen betweenness > 0: la inmensa mayoría no intermedia nada porque pertenece a una sola clique de video. Fuerza y betweenness ordenan distinto, lo que confirma que un ranking de grado no basta para llamar 'puente' a un nodo.

Para los autores conviene separar cuatro cosas que suelen confundirse en un solo concepto de «usuario activo»:

Tabla 54. Cuatro dimensiones distintas de la participacion de un autor

Dimension	Como se mide	Valor en estos datos
Recurrencia	Numero de comentarios publicados	46 autores con mas de uno; maximo 6
Amplitud de contenido	Numero de videos distintos comentados	9 autores en mas de un video; maximo 3
Diversidad de emisores	Numero de canales distintos comentados	4 autores en mas de un canal; maximo 2
Papel estructural	Betweenness y condicion de puente verificado	9 con betweenness > 0 (2.7%); 7 puentes verificados

Las cuatro dimensiones no coinciden, y ahi esta el hallazgo. Un autor puede ser muy recurrente y estructuralmente irrelevante: el mas activo del conjunto publico 6 comentarios, todos en el mismo video, y tiene betweenness 0. A la inversa, un autor con 2 comentarios en 2 videos de canales distintos puede ser el unico vinculo entre dos bloques de contenido. **Actividad y centralidad estructural son propiedades independientes en esta muestra.**

Tabla 55. Top 10 autores por betweenness ponderada

#	Handle	Com.	Videos	Canales	Grado	Fuerza	Betweenness	PageRank	Articulacion
1	@virgiliogarcia3039	3	2	2	145	145	0.23902	0.00524	si
2	@inge_vergueta	3	3	1	183	184	0.22028	0.00733	si
3	@josegil3813	2	2	1	49	49	0.18266	0.00510	si
4	@Jel.Awesh.M	3	2	1	174	175	0.09365	0.00573	no
5	@franciscoflores3120	2	2	2	43	43	0.05779	0.00532	si
6	@hashojea7348	4	3	1	28	29	0.05740	0.00619	si
7	@Alejandro00710	2	2	1	23	24	0.03268	0.00454	no
8	@moisesvaldez4043	2	2	2	133	133	0.02955	0.00468	si
9	@MarcosCarillo-b1r	2	2	2	54	54	0.02955	0.00442	si
10	@normaleticiaorozcojuarez2418	1	1	1	127	127	0.00000	0.00327	no

Tabla 56. Top 10 autores por recurrencia (numero de comentarios)

#	Handle	Com.	Videos	Canales	Betweenness
1	@Murmullodelbarrio	6	1	1	0.00000
2	@eugeneramirez4405	6	1	1	0.00000
3	@ManuelEdran	5	1	1	0.00000
4	@albertoshernandez5251	5	1	1	0.00000
5	@hashojea7348	4	3	1	0.05740
6	@ErvinLeonardoCarreraLatín	4	1	1	0.00000
7	@virgiliogarcia3039	3	2	2	0.23902
8	@inge_vergueta	3	3	1	0.22028
9	@Jel.Awesh.M	3	2	1	0.09365
10	@marioajset4283	3	1	1	0.00000

El contraste entre las tablas 55 y 56 es directo: casi ninguno de los autores mas recurrentes aparece entre los de mayor intermediacion, y varios de los intermediadores tienen apenas 2 o 3 comentarios. La fuerza en la proyeccion de autores tampoco sirve como proxy: esta dominada por el tamaño de la audiencia del video comentado, no por el papel del autor (quien comento el video de 128 comentaristas tiene fuerza altísima por el simple hecho de estar en esa clique).

12.3 Autores puente: identificacion y verificacion

Un autor se declara puente **solo si pasa una prueba de eliminacion**: se lo retira de la red bipartita, se recalcula la proyeccion video-video y se cuenta si aumento el numero de componentes conexas. De los 9 autores con mas de un video, **7 superan la prueba**.

Tabla 57. Todos los autores con participacion en mas de un video

Handle	Com.	Videos	Canales	Com.-dades	Puente verificado	Δ componentes	Videos que conecta
@hashoja7348	4	3	1	1	SI	+1	Arroz con pollo a la MONOPOLIO Caminar en una ci...
@inge_vergueta	3	3	1	2	SI	+1	Internet: escoger el menos malo La cooptación de...
@virgiliogarcia3039	3	2	2	2	SI	+1	Conferencia de Prensa del Gobierno de Guatemala. #L...
@MarcosCarillo-b1r	2	2	2	1	SI	+1	Capturan a ladrón que había quedado grabado mientra...
@franciscoflores3120	2	2	2	1	SI	+1	Capturan a presuntos delincuentes disfrazados de mu...
@moisesvaldez4043	2	2	2	1	SI	+1	Bloqueos en Guatemala este 31 de agosto por alza en...
@josegil3813	2	2	1	1	SI	+1	Conferencia de Prensa del Gobierno de Guatemala. #L...
@Jel.Awesh.M	3	2	1	1	no	0	La cooptación de Walter Mazariegos en la USAC Qu...
@Alejandro00710	2	2	1	1	no	0	Arroz con pollo a la MONOPOLIO Internet: escoger...

Dos de los nueve autores multivideo **no** son puentes: su conexion entre videos esta duplicada por otro autor, de modo que retirarlos no parte nada. Es exactamente la distincion que la prueba de eliminacion permite hacer y que un ranking de grado no. Los siete restantes son, en el sentido estricto del enunciado, los participantes cuya eliminacion segmenta la red.

12.4 Videos: alcance y capacidad de conectar audiencias

Tabla 58. Centralidad de los videos en la proyeccion video-video

Video	Canal	Com. obs.	Vistas	Grado	Fuerza	Betweenness	PageRank	Articulacion
Qué rico come tu diputado	Quorum	161	11 775	4	5	0.1503	0.1587	si
Internet: escoger el menos malo	Quorum	12	717	4	5	0.0915	0.1439	si
Conferencia de Prensa del Gobiern...	Gobierno de la Re...	25	3 628	2	2	0.0915	0.0787	si
La cooptación de Walter Mazariego...	Quorum	50	10 156	3	4	0.0523	0.1255	si
Inician los trabajos de recuperac...	Gobierno de la Re...	45	11 670	2	2	0.0523	0.0907	si
Arroz con pollo a la MONOPOLIO	Quorum	16	1 954	2	3	0.0000	0.0889	no
Caminar en una ciudad hecha para ...	Quorum	6	422	2	2	0.0000	0.0629	no
Capturan a presuntos delincuentes...	Noti7	14	6 692	1	1	0.0000	0.0517	no
Bloqueos en Guatemala este 31 de ...	PrensaLibreOficial	7	5 469	1	1	0.0000	0.0402	no
Capturan a ladrón que había queda...	TN23 Guatemala	7	4 616	1	1	0.0000	0.0399	no

El alcance de un video dentro de la red **no se deriva de su popularidad**. Como se cuantifico en la pregunta 7.5, la correlacion entre visualizaciones y grado en la proyeccion no es significativa, mientras que la correlacion con el numero de comentarios observados si lo es. El video mas visto de la muestra («Plan 2032 Ciudad de Guatemala», 304 089 vistas) tiene grado 0 y betweenness 0: no conecta con nada. El mas central es «Que rico come tu diputado», que tiene 26 veces menos visualizaciones pero 161 comentarios recolectados.

12.5 Videos articuladores

Igual que con los autores, la condicion de articulador se verifica eliminando el nodo y recontando componentes. La tabla registra el estado antes y despues para que la afirmacion sea auditable:

Tabla 59. Nodos articuladores verificados por red

Red	Nodo	Canal	Grado	Comp. antes	Comp. tras	Delta	Mayor antes	Mayor tras	Aislados tras
Proy. video-video	Qué rico come tu diputado	Quorum	4	10	12	+2	10	5	10
Proy. video-video	Internet: escoger el menos ...	Quorum	4	10	11	+1	10	7	9
Proy. video-video	La cooptación de Walter Maz...	Quorum	3	10	11	+1	10	8	10
Proy. video-video	Inician los trabajos de rec...	Gobierno de la ...	2	10	11	+1	10	8	10
Proy. video-video	Conferencia de Prensa del G...	Gobierno de la ...	2	10	11	+1	10	7	9

En la proyeccion video-video hay 5 videos articuladores de 19. El de mayor impacto es «Que rico come tu diputado»: al eliminarlo, la componente mayor pasa de 10 a 4 videos y se generan nodos aislados nuevos. Ese video es el

punto de paso de la mayor parte de la audiencia compartida del corpus, y no por su alcance publicitario sino porque es donde mas gente recolectada comento.

Tabla 60. Numero de articuladores verificados por red

Red	Articuladores verificados	Nodos totales
Bipartita	22	351
Proy. autor-autor	7	332
Proy. video-video	5	19

La red bipartita tiene 22 nodos articuladores, que incluyen tanto videos como los autores puente. Es coherente con $k = 1$ en su componente mayor: la conectividad de esta red depende de nodos individuales, no de redundancia estructural.

Advertencia sobre la fragilidad de estos resultados. Que un nodo sea articulador es una propiedad exacta *del grafo observado*, no una propiedad robusta del fenomeno. Todos los articuladores identificados lo son porque una unica persona sostiene una unica conexion. Con una recoleccion de comentarios mas completa, casi con certeza aparecerian conexiones alternativas y varios de estos nodos dejarian de ser criticos. Se reportan porque responden a lo que el enunciado pide y porque estan correctamente verificados, no porque describan una vulnerabilidad estructural de YouTube.

13. Analisis de contenido

13.1 Enfoque elegido y por que no un modelo de topicos

La caracterizacion de contenido se hace con **TF-IDF por comunidad, frecuencias, bigramas y las keywords del contenido publicado**, no con un modelo de topicos probabilistico. La decision es de adecuacion al tamano del corpus: hay 406 comentarios con una mediana de 9.4 tokens utiles tras la limpieza, repartidos en comunidades de entre 6 y 225 documentos. Un LDA o un BERTopic estarían estimando muchos parametros sobre muy pocos datos, sus topicos no serían estables entre corridas y su interpretacion exigiria mas supuestos de los que los datos sostienen.

TF-IDF, en cambio, responde exactamente la pregunta pertinente —**que terminos distinguen a esta comunidad del resto del corpus**— con una sola decision de disenio explicita: el IDF se calcula tomando cada comunidad como un documento, de modo que un termino frecuente en todas ellas (como «guatemala») queda penalizado y emergen los terminos diferenciadores. Se complementa con las keywords y titulos de los videos, que provienen del emisor y no del comentarista, lo que permite cruzar dos fuentes independientes de senal tematica.

13.2 Terminos distintivos por comunidad

Tabla 61. Terminos TF-IDF de los comentarios por comunidad (top 6)

Comunidad	1.º	2.º	3.º	4.º	5.º	6.º
C0	diputado	pueblo	sueldo	almuerzo	corrupto	ganar
C1	presidente	presidente bernardo	terminar	puente	bernardo arevalo	senor
C2	empresa	internet	tigo	libre	competencia	cliente
C3	semiya	semiya perder	recuerdo	recuerdo dejar	reduce	problema recuerdo
C4	semilla	semilla bernardo	saliera	saliera corrupcion	oportunidad	oportunidad guatemala
C5	entrar	deportar	crimar	entrar ilegalmente	pertenecen	familia
C6	iniciativa	juego	excelente iniciativa	excelente	tradicion	trasfondo juego
C7	video importante	tipo espacio	espacio	importante tipo	importante	tipo
C8	telefono	telefono colocado	telguo	telguo whatsapp	subscribir	subscribir boletin
C9	ciudad	ciudad guatemala	saludos	guatemala	cuidad	guatemala saludos
C10	woow					

Tabla 62. Keywords y titulos TF-IDF del contenido publicado (top 5)

Comunidad	1.º	2.º	3.º	4.º	5.º
C0	usac	noticias guatemala	mazariegos	noticias	combustibles
C1	disfrazados	noticias	del	de	belice
C2	internet	arroz	caminar	arroz con	telefonía
C3	noticiero	guatevision	directo	en directo	emisión
C4	nacional	paro	paro nacional	10	año
C5	telemundo	mexicanos	noticias	noticias telemundo	telemundo noticias
C6	únicamente por	únicamente	at	at el	por mujeres
C7	wa la	wa	vecina queer	shai	shai wa
C8	transmetro	zona18 centrasur	zona18	transmetro ciudaddeguatemala	puro
C9	plan 2032	plan	público	movilidad	2032
C10	impuestos	rica	quiénes	rica panamá	regresivas
C11	antigua	antigua super	super	super episodio	salud

Las dos tablas convergen en las tres comunidades no triviales, y esa convergencia es lo que autoriza a ponerles una etiqueta tematica. En C0 los comentarios hablan de *diputado*, *pueblo*, *sueldo*, *almuerzo*, *corrupto* y las keywords del contenido dicen *usac*, *mazariegos*, *combustibles*: el mismo campo de fiscalizacion del poder publico visto desde los dos lados. En C1 los comentarios dicen *presidente*, *bernardo arevalo*, *puente* y las keywords *belice*,

disfrazados. En C2 los comentarios dicen *empresa, internet, tigo, competencia* y las keywords *internet, telefonía, caminar*.

Cuando la convergencia no existe, no se pone etiqueta. Los nueve singletons no reciben nombre temático de comunidad: con un solo video no hay forma de distinguir el tema del video del tema de una supuesta comunidad. Se describen por su contenido individual en la tabla 52.

13.3 Vocabulario global de los comentarios

Tabla 63. 20 palabras, 15 bigramas y 10 trigramas mas frecuentes

#	Palabra	Frec.	Bigrama	Frec.	Trigrama	Frec.
1	pueblo	56	bernardo arevalo	10	presidente bernardo arevalo	9
2	guatemala	51	presidente bernardo	9	morir el hambre	3
3	diputado	50	ciudad guatemala	6	diputado nery roda	3
4	el	46	buscar trabajo	5	apoyo presidente bernardo	3
5	pagar	39	dar el	5	suelo buscar trabajo	2
6	dinero	34	nery roda	5	pueblo morir el	2
7	presidente	32	pueblo pagar	5	vivo presidente bernardo	2
8	corrupto	30	bla bla	5	ley competencia seguir	2
9	trabajo	29	pagar sueldo	5	destapo corrupcion existia	2
10	seguir	23	pacto corrupto	5	corrupcion existia contaminao	2
11	excelente	22	vivo guatemala	4	existia contaminao ampliacion	2
12	suelo	20	diputado alcanzar	4	contaminao ampliacion deuda	2
13	trabajar	20	morir el	4	ampliacion deuda comunidad	2
14	empresa	19	gastar dinero	4	deuda comunidad internacional	2
15	proyecto	19	pagar dinero	4	comunidad internacional prestar	2
16	almuerzo	17	canasta basico	4	internacional prestar carretero	2
17	senor	17	dinero pueblo	4	prestar carretero concesion	2
18	dejar	15	excelente video	4	carretero concesion aeropuerto	2
19	persona	15	senor presidente	4	concesion aeropuerto puerto	2
20	arevalo	15	pagar comida	4	aeropuerto puerto carretero	2

La caída de frecuencias entre los tres niveles de n-grama es la firma de un corpus sin coordinación: la palabra mas frecuente aparece 56 veces, el bigrama mas frecuente 10 y el trigrama mas frecuente 9. Si hubiera consignas repetidas, campanas coordinadas o texto copiado, los trigramas mantendrian frecuencias altas. No lo hacen: cada comentario es una redacción individual. Esto es relevante para descartar automatización como explicación de la concentración documentada en la sección 5.2.

13.4 Contenido desde el lado del emisor

Tabla 64. 15 keywords mas frecuentes en el catalogo de videos

#	Keyword	Frecuencia
1	guatemala	89
2	noticias	28
3	noticias guatemala	20
4	municipalidad	19
5	muni	18
6	servir	16
7	administración	16
8	alcalde	16
9	cumple	16
10	equipo	16
11	transparencia	16
12	pasión	16
13	todos	16
14	somos	16
15	ciudad	16

Las keywords las escribe el canal para posicionar su contenido, no la audiencia. Su comparacion con el vocabulario de los comentarios muestra un desajuste sistematico: los canales etiquetan con terminos de identificacion institucional y geografica, mientras que los comentaristas escriben sobre personas concretas y dinero. Es una diferencia entre el marco que propone el emisor y el marco con el que responde la audiencia.

13.5 Emojis

Tabla 65. 12 emojis mas frecuentes en los comentarios

Emoji (descripcion)	Frecuencia
cara llorando de risa (U+1F602)	29
bandera guatemala (U+1F1EC U+1F1F9)	19
manos aplaudiendo (U+1F44F)	17
cañón de confeti (U+1F389)	15
pulgar hacia arriba (U+1F44D)	14
cara cabreada (U+1F621)	8
cara con la boca abierta (U+1F62E)	8
cara sonriendo con sudor frío (U+1F605)	7
cara llorando (U+1F622)	7
demonio japonés oni (U+1F479)	6
bandera estados unidos (U+1F1FA U+1F1F8)	6
caca con ojos (U+1F4A9)	5

Hay 199 emojis en 61 de 406 comentarios (15.0%). Se eliminan de `texto_limpio` porque en una bolsa de palabras no son terminos, pero **se conservan y se traducen a texto en la entrada del modelo de sentimiento**, donde si aportan senal. La tabla se incluye porque el uso de emojis resulta ser informativo por si mismo: como se ve en la seccion 14, la proporcion de comentarios con emoji es el doble en los positivos que en los negativos.

14. Modelo y analisis de sentimiento

14.1 Modelo utilizado y justificacion

Tabla 66. Identificacion del modelo

Campo	Valor
Identificador	pysentimiento/robertuito-sentiment-analysis
Arquitectura	RobertaForSequenceClassification (roberta)
Parametros	108 791 043
Capas / hidden size	12 / 768
Tokenizer	TokenizersBackend, 30 000 tokens
Framework	PyTorch via HuggingFace transformers, transformers 5.16.1, torch 2.14.0+cu130
Clases	NEG / NEU / POS
max_length / truncation / batch	128 / True / 32
Dispositivo	cpu (Linux 6.18.33.2-microsoft-standard-WSL2 (x86_64))
Semilla	42
Fecha de ejecucion (UTC)	2026-09-07T03:52:28+00:00
Tiempo de inferencia	25.73 s (15.8 com./s)

Por que este modelo y no un lexico. RoBERTuito es un RoBERTa preentrenado desde cero sobre aproximadamente 500 millones de tweets en espanol y afinado para polaridad con el corpus TASS 2020. Cumple tres condiciones que los comentarios de este conjunto exigen: es un modelo **de espanol**, no multilingue, de modo que su vocabulario no compite con otras cien lenguas; su dominio de preentrenamiento es **texto informal de redes sociales**, que comparte con los comentarios de YouTube la brevedad, los emojis y la ortografia libre; y devuelve **tres clases con probabilidades**, lo que permite reportar distribucion y confianza sin inventar umbrales.

Por que se descartaron TextBlob y VADER. Los dos son herramientas razonables para ingles y las dos fallarian aqui por la misma razon: sus lexicos son de ingles. Aplicados a texto espanol, la mayoría de los tokens quedaria fuera de diccionario y el resultado seria una masa de polaridad cero producida por ausencia de vocabulario, no por neutralidad de los textos. Eso no es una medicion con sesgo: es una no-medicion. Un lexico de sentimiento en espanol seria mejor, pero seguiria sin modelar la negacion («no me gusta») ni el contexto de la oracion, que un transformer si captura.


14.2 Texto de entrada y preprocesamiento

La inferencia se hace sobre `texto_original`, **no sobre** `texto_limpio`. La razon es que la version tematica elimina precisamente lo que porta polaridad: mayusculas, signos de exclamacion, emojis y stopwords. «NO me gusta» y «me gusta» son identicos tras quitar stopwords, y opuestos en sentimiento.

Sobre el texto original se aplica la normalizacion que el modelo vio en entrenamiento (menciones a `@usuario`, URL a `url`, hashtags sin `#`, emojis traducidos a su descripcion en espanol entre delimitadores, repeticiones acortadas y risa normalizada). El detalle completo esta en la seccion 4 del reporte del modelo (`results/model/sentiment_model_report.md`).

14.3 Resultados globales

Figura 26. Sentimiento de los comentarios: distribución y confianza



El 61.58% de los comentarios se clasifica como negativo, 18.97% neutro y 19.46% positivo. La confianza mediana es 0.8685, y 3.94% de las predicciones tiene confianza < 0.5, casos que deben leerse como indecision del modelo y no como neutralidad del autor.

Tabla 67. Distribucion de clases y confianza

Clase	Significado	n	%	Confianza media	Confianza mediana
NEG	polaridad negativa (critica, queja, rechazo, insulto)	250	61.6%	0.8638	0.9148
NEU	polaridad neutra (informativo, pregunta, sin carga afectiva clara)	77	19.0%	0.6285	0.5893
POS	polaridad positiva (aprobacion, agradecimiento, elogio, apoyo)	79	19.5%	0.8083	0.8579


61.6% de los comentarios se clasifica como negativo, frente a 19.0% neutro y 19.5% positivo, lo que da una polaridad neta de -42.1 puntos porcentuales. La cobertura es total: los 406 comentarios recibieron prediccion (100.0%), sin fallos ni exclusiones.

La confianza mediana es 0.8685 y solo 16 predicciones (3.9%) quedan por debajo de 0.5. Es un perfil de confianza alto, aunque 40 predicciones (9.8%) tienen un margen menor a 0,2 entre la primera y la segunda clase, es decir, son casos donde el modelo esta dividido.

Confianza no es polaridad. La confianza es la probabilidad de la clase mas probable, no una medida de intensidad de polaridad. Una prediccion NEG con confianza 0.95 no es 'mas negativa' que una con 0.60: es una clasificacion mas segura.

14.4 Comparaciones por grupo

Figura 27. Composicion de sentimiento por video y por canal



El n de cada grupo aparece en su etiqueta: los grupos pequenos no son comparables. Restringido a canales con $n \geq 10$, la prueba chi-cuadrado da $\chi^2=82.0701$ ($gl=8$, $p=0.0$), significativa al 5%: V de Cramer = 0.3244.

Las comparaciones formales se limitan a los grupos con $n \geq 10$ y el n de cada uno aparece siempre visible. De 19 videos, 9 son comparables; de 8 canales, 5; de 12 comunidades, 5.


Tabla 68. Pruebas de independencia entre grupo y clase de sentimiento

Agrupacion	Grupos incl.	n	chi-cuadrado	gl	p	V de Cramer	Signif. 5 %
Por canal	5	390	82.0701	8	0.0	0.3244	si
Por video	9	373	115.2920	16	0.0	0.3931	si
Por comunidad	5	393	100.3471	8	0.0	0.3573	si
Por categoria	2	405	6.5293	2	0.03821	0.1270	si

Tabla 69. Composicion de sentimiento por canal ($n \geq 10$)

Canal	n	% NEG	% NEU	% POS	Polaridad neta	Mayoritaria
Quorum	256	69.9%	15.6%	14.4%	-55.5	NEG
Gobierno de la República de Guate...	70	48.6%	27.1%	24.3%	-24.3	NEG
Noticias Telemundo	25	72.0%	20.0%	8.0%	-64.0	NEG
Municipalidad de Guatemala	25	8.0%	12.0%	80.0%	+72.0	POS
Noti7	14	28.6%	50.0%	21.4%	-7.1	NEU

La composicion difiere entre canales de forma significativa (chi-cuadrado = 82.0701, $gl = 8$, $p = 0.0$, V de Cramer = 0.3244), y la direccion del efecto es clara: **el contraste mas fuerte del conjunto no es entre temas sino entre tipos de emisor**. La Municipalidad de Guatemala es el unico canal con mayoria de comentarios positivos (80,0 %), mientras que el periodismo de investigacion y los noticieros concentran entre 50 % y 86 % de comentarios negativos.




Las comunidades difieren en polaridad neta, pero la comparacion formal solo incluye las de $n \geq 10$. Chi-cuadrado: $\chi^2=100.3471$, $p=0.0$. La direccion del signo es el hallazgo interpretable; su magnitud exacta depende de muestras pequenas.

Tabla 70. Composicion de sentimiento por comunidad

Comunidad	Videos	n comentarios	% NEG	% NEU	% POS	Polaridad neta	Comparable
C0	4	225	76.0%	15.1%	8.9%	-67.1	si
C1	3	84	45.2%	30.9%	23.8%	-21.4	si
C2	3	34	50.0%	20.6%	29.4%	-20.6	si
C5	1	25	72.0%	20.0%	8.0%	-64.0	si
C9	1	25	8.0%	12.0%	80.0%	+72.0	si
C6	1	4	25.0%	0.0%	75.0%	+50.0	NO
C4	1	3	33.3%	0.0%	66.7%	+33.3	NO
C3	1	2	50.0%	50.0%	0.0%	-50.0	NO
C7	1	1	0.0%	0.0%	100.0%	+100.0	NO
C8	1	1	100.0%	0.0%	0.0%	-100.0	NO
C10	1	1	0.0%	0.0%	100.0%	+100.0	NO
C11	1	1	0.0%	100.0%	0.0%	+0.0	NO

Entre comunidades la diferencia tambien es significativa (chi-cuadrado = 100.3471, $p = 0.0$, V de Cramer = 0.3573). El orden es el descrito en la seccion 11: C0 (fiscalizacion del poder publico) es la mas negativa, C1 (comunicacion del Ejecutivo) la mas mixta, y C2 (regulacion economica) la de mayor proporcion positiva. Siete de las doce comunidades tienen $n < 10$ y se marcan como no comparables.

14.5 Sentimiento y metricas de interaccion



Los comentarios negativos tienen una mediana de 0.0 'me gusta' frente a 2.0 de los positivos. Es una asociacion descriptiva sobre conteos parciales al momento de la recoleccion, no evidencia de que la negatividad genere aprobacion.

Tabla 71. Asociacion entre clase de sentimiento y metricas observadas

Clase	«Me gusta» mediana	«Me gusta» media	Longitud mediana (car.)	% con emoji
NEG	0	1.66	132	11.2%
NEU	1	7.40	41	18.2%
POS	2	16.97	76	24.1%

El patron es consistente y se cuantifico formalmente en la pregunta 7.4: los comentarios negativos son los **mas largos** (mediana 132 caracteres frente a 76 de los positivos) y los que reciben **menos aprobacion** (mediana 0 «me gusta» frente a 2), y los positivos son los que mas usan emojis (24.1% frente a 11.2%). En esta muestra la critica se argumenta mas y se premia menos.

Esta asociacion es **descriptiva**. No permite concluir que la negatividad reduzca los «me gusta»: los conteos son parciales y tomados en un momento, los comentarios positivos podrian ser mas breves por ser formulas de apoyo faciles de aprobar, y la seleccion de videos condiciona ambos lados de la relacion.

14.6 Ejemplos y casos ambiguos

Los ejemplos se eligen por posicion en la distribucion de confianza (maxima, mediana y minima de cada clase), no a mano. Dos por clase:

- «Que indignante saber como se artan estos coches y finalmente el pueblo esta ciendo dañado» — predicho **NEG** con confianza 0.986
- «Me pregunto si antes de ser diputados les alcanzaba su dinero para comer esos almueritos y en esos lugares? Pero como don pueblo paga....vengase el almuerito. La historia ni él se la cree...» — predicho **NEG** con confianza 0.915
- «Pregúntenle si se acuerda de la marca del vino que se toma todos los días» — predicho **NEU** con confianza 0.885
- «Así metan los al tambo con minifaldas allí no les ba a faltar la moronga.» — predicho **NEU** con confianza 0.589
- «Es un proyecto extraordinario , vamos adelante mi guate hermosa!» — predicho **POS** con confianza 0.978
- «Guatemala nunca se tube que llamar guatemala dino guatebella guatehermosa guatelinda la eterna primavera es guatebella abrazos hnos de un salvadoreno que viva el amor y la armonia» — predicho **POS** con confianza 0.915

Los seis comentarios de menor confianza de todo el corpus:

- «Este hombre esta loco» — predicho **NEU** con confianza 0.355
- «Ay ricos shucos en la calle jajaja» — predicho **NEG** con confianza 0.435
- «" Ayudanos a luchar contra el racismo y los malos tratos; vete de regreso a tu pais" Someone.» — predicho **NEU** con confianza 0.442
- «Mantenidos» — predicho **NEU** con confianza 0.470
- «Pero hay que ver el lado bueno si los deportan por la Frontera los carteles los secuestran para sacar dinero a los familiares en USA» — predicho **NEU** con confianza 0.473
- «Despues de tanta corrupcion y desfalco por los anteriores gobiernos ladrones que esperaba Rolando? ahora si se puede ver que los fondos de nuestros impuestos se estan usando en lo que deberi...» — predicho **POS** con confianza 0.473

La inspeccion de estos casos muestra exactamente donde falla el modelo: la ironia («Ay ricos shucos en la calle jajaja» es una burla y recibe NEG con 0,435 de confianza), el sarcasmo citado entre comillas, las expresiones de una palabra sin contexto («Mantenidos») y el lexico guatemalteco ausente del corpus de entrenamiento («shucos», «tambo», «moronga»). El reporte completo del modelo, con las trece limitaciones documentadas y la referencia a la model card, esta en `results/model/sentiment_model_report.md`.

La etiqueta del modelo es una prediccion estadistica sobre la superficie del texto. NO equivale a la intencion real del autor ni a su estado emocional. Ademias, no se dispone de un conjunto etiquetado a mano de este dominio, por lo que **no se puede reportar exactitud ni F1 sobre estos datos**. Las cifras de esta seccion describen la distribucion de las predicciones, no su correccion.

15. Interpretación integrada

Esta sección cruza los tres bloques de resultados —estructura de red, contenido y sentimiento— para responder que se observó sobre la participación y el consumo de contenido en esta muestra de YouTube. Cada afirmación se etiqueta según su estatus epistémico, siguiendo la distinción que el inciso 10.3 exige.

15.1 Hallazgo 1: consumo paralelo, no conversación

Descripción. El 93.2% de los nodos de la red bipartita tiene grado 1. 286 de 332 autores (86.1%) publicaron un único comentario y solo 9 (2.7%) comentaron en más de un video. La asortatividad de grado es -0.428 y la transitividad es 0 por construcción; el clustering bipartito de Latapy es 0.892. Solo 30 comentarios (7.4%) recibieron alguna respuesta.

Que significa en esta muestra. La estructura observada es la de audiencias paralelas: videos-hub rodeados de comentaristas que aparecen una sola vez y no vuelven. El acto típico no es participar en una discusión sino dejar una opinión y salir. Es coherente con el análisis de contenido: la caída abrupta de frecuencias entre palabras, bigramas y trigramas indica redacciones individuales sin consignas repetidas ni coordinación.

Que no puede concluirse. No puede concluirse que los usuarios de YouTube no conversen. Los datos contienen **solo comentarios principales**: las respuestas existen (se sabe que hubo 51) pero no están en el conjunto, y sin ellas cualquier medida de conversación está truncada por construcción. Tampoco puede concluirse que un autor «solo comentó una vez»: comentó una vez *en los videos recolectados*.

15.2 Hallazgo 2: la concentración es de atención, no de voz

Descripción. Gini de 0.6596 por video y 0.6644 por canal, frente a un Gini de solo 0.1643 por autor. Los tres videos más comentados acumulan 63.0% de los comentarios y el canal líder 63.0%; el autor más activo, 1.5%.

Que significa. Unos pocos contenidos capturan casi toda la participación, pero dentro de ellos la palabra se reparte entre cientos de personas distintas. No hay un grupo reducido de usuarios dominando la conversación —el escenario que suele preocupar en análisis de redes sociales— sino un grupo reducido de videos que concentra la atención. Es una asimetría de agenda, no de voz.

Que no puede concluirse. Parte de esta concentración es artefacto del muestreo: el canal líder fue objeto de un barrido específico (@quorumgt/videos, que aporta 231 de 406 comentarios), lo que garantiza su peso independientemente de su volumen real de conversación.

15.3 Hallazgo 3: la audiencia compartida es mínima y frágil

Descripción. La proyección video-video tiene 11 aristas de 171 posibles (densidad 0.0643), con pesos de 1 o 2, y 9 de 19 videos aislados. κ global es 0 en las tres redes y κ en la componente mayor es 1. De 332 autores, 7 son puentes verificados por prueba de eliminación y solo 9 (2.7%) tienen betweenness positiva.

Que significa. Los contenidos de esta muestra tienen públicos casi disjuntos, y las conexiones que existen las sostienen individuos concretos, no una malla redundante. La asimetría entre κ por nodos (1) y por aristas (5) en la proyección de autores lo resume: hay que cortar cinco vínculos para partirla, pero basta retirar a una persona.

Que no puede concluirse. Ninguna de estas cifras describe aislamiento real en YouTube. Con comentarios recolectados en solo 19 de 293 videos, la probabilidad de **detectar** solapamiento es estructuralmente baja. El caso ilustrativo es «Plan 2032 Ciudad de Guatemala»: 304 089 visualizaciones, el video más visto del corpus, y grado 0 en la proyección. Su aislamiento es un dato sobre la cobertura del muestreo, no sobre su público.

15.4 Hallazgo 4: la estructura de audiencia coincide con la estructura tematica

Descripcion. Louvain sobre la proyeccion video-video devuelve 12 comunidades (Q ponderada = 0.4053), de las cuales 3 son no triviales. La particion coincide exactamente con la de greedy modularity ($NMI = 1,0$). Las tres comunidades tienen terminos TF-IDF de comentarios y keywords de contenido publicado que convergen en el mismo campo semantico, y difieren en composicion de sentimiento de forma significativa ($\chi^2 = 100.3471$, $p = 0.0$, V de Cramer = 0.3573).

Que significa. Las comunidades detectadas por **audiencia compartida** resultan interpretables por **tema** y por **polaridad**, aunque ni el tema ni la polaridad entraron en el algoritmo: Louvain solo vio numeros de autores compartidos. Que tres senales independientes converjan es lo que autoriza a poner una etiqueta tematica a cada comunidad. Y el eje que las ordena es reconocible: la relacion del comentarista con el poder institucional, de la fiscalizacion (C0, la mas negativa) a la comunicacion gubernamental (C1, mixta) y a la regulacion economica (C2, la mas positiva).

Que no puede concluirse. La modularidad de 0.4053 no debe leerse como evidencia de estructura comunitaria fuerte: en un grafo de 11 aristas y 10 componentes, un valor asi se obtiene con facilidad. Ademas 9 de las 12 comunidades son singletons, de modo que la particion cubre solo el 52.6% de los videos. La correspondencia con la consulta de recoleccion, medida con ARI corregido por azar, es baja (0,083), lo que descarta que las comunidades sean una relectura del muestreo, pero el muestreo si determina que agrupamientos pueden llegar a observarse.

15.5 Hallazgo 5: la critica se argumenta mas y se premia menos

Descripcion. 61.6% de los comentarios se clasifica como negativo (polaridad neta -42.1 p. p.). Los negativos tienen la longitud mediana mas alta (132 caracteres frente a 76 de los positivos; Kruskal-Wallis $p < 0,001$) y la mediana de «me gusta» mas baja (0 frente a 2; $p \approx 1e-06$). Los positivos usan emojis con el doble de frecuencia (24.1% frente a 11.2%).

Que significa. Hay dos registros distintos de participacion en la misma muestra: uno critico, extenso y argumentado, y otro de apoyo, breve y con emojis. El primero es mayoritario en volumen y el segundo en aprobacion recibida por comentario. El contraste mas fuerte no se da entre temas sino entre **tipos de emisor**: el unico canal con mayoría de comentarios positivos es una institucion municipal presentando un plan urbano, mientras que el periodismo de investigacion y los noticieros concentran la critica.

Que no puede concluirse. Nada causal. No se puede afirmar que la negatividad reduzca los «me gusta»: los conteos son parciales y de un momento dado, y los comentarios de apoyo podrian ser breves precisamente por ser formulas faciles de aprobar. Tampoco se puede afirmar que el publico guatemalteco sea mayoritariamente critico: el corpus esta dominado por videos de politica y de sucesos recuperados por consultas como `guatemala politica` y `guatemala seguridad`, que atraen ese registro por construccion. Y las etiquetas son predicciones de un modelo, no la intencion de los autores.

15.6 Hallazgo 6: la visibilidad ordena la participacion pero no la determina

Descripcion. Entre los 19 videos con comentarios recolectados, ρ de Spearman entre visualizaciones y comentarios observados es 0.8115 ($p = 2e-05$). Pero el video mas visto (304 089 vistas) tiene 25 comentarios observados y grado 0 en la red, mientras que el mas comentado (161 comentarios, 11 775 vistas) es el nodo mas central. La correlacion entre visualizaciones y grado en la proyeccion no es significativa ($\rho = 0,289$, $p = 0,231$), mientras que la de comentarios observados con grado si ($\rho = 0,678$, $p = 0,001$).

Que significa. La visibilidad y la participacion se ordenan de forma parecida, pero el **papel estructural** de un video en la red de audiencia compartida depende de la participacion recolectada y no de su alcance. Ser muy visto no convierte a un video en punto de encuentro de publicos distintos.

Que no puede concluirse. Ni causalidad ni generalizacion. La direccion causal es ambigua en ambos sentidos (mas vistas dan mas oportunidades de comentar, pero mas discusion tambien atrae mas recomendaciones del algoritmo). El eje de comentarios mide cobertura de recoleccion tanto como participacion. Y las visualizaciones son un corte temporal: dos videos publicados en fechas distintas no son comparables sin ajustar por antigüedad, correccion imposible con fechas relativas. Ademas los videos observados no son los mas vistos del catalogo

(Mann-Whitney $p = 0.20265$), así que la relación se estima sobre un subconjunto no elegido por popularidad.

16. Limitaciones

Las limitaciones se ordenan por su capacidad de invalidar conclusiones, de mayor a menor, y cada una indica **que afirmacion concreta de este informe restringe**.

16.1 Cobertura incompleta de comentarios

Solo 19 de 293 videos (6.5%) tienen comentarios en el conjunto, y no hay garantia de que se hayan recolectado todos los comentarios de esos 19. **Restringe:** toda cifra de volumen de participacion, la densidad y la fragmentacion de las redes, el numero de componentes, la identidad de los puentes y los articuladores, y la existencia de videos aislados. Es la limitacion dominante del trabajo.

16.2 Seleccion de videos por consultas de busqueda

El catalogo se construyo con 21 consultas que mezclan busquedas tematicas (guatemala lluvias, guatemala noticias), canales oficiales de gobierno y barridos de canales especificos. En los comentarios solo sobreviven 6 consultas y una sola (@quorumgt/videos) aporta 231 de 406 comentarios (56.9%). **Restringe:** la composicion tematica observada, el predominio de News & Politics, la identidad de las comunidades y la distribucion global de sentimiento. Un corpus construido con consultas sobre deporte o musica daría un retrato distinto.

16.3 Fechas relativas y sin resolucion

published_text (comentarios) y published_time (videos) son tiempos relativos al momento de recoleccion («hace 2 años»), redondeados por YouTube. No hay ninguna fecha absoluta de comentario en el conjunto. **Restringe:** cualquier analisis temporal, de evolucion o de causalidad temporal; la comparacion de acumulados entre videos de distinta antigüedad; y la posibilidad de normalizar visualizaciones o «me gusta» por tiempo de exposicion.

16.4 Conteos observados en el momento de la recoleccion

view_count, like_count_text y reply_count son cortes temporales, no totales finales. Un video de hace dos años y uno de hace dos días no son comparables sin normalizar, y esa normalizacion es imposible por la limitacion anterior. **Restringe:** la comparacion de popularidad entre videos, la correlacion entre visualizaciones y participacion, y la asociacion entre sentimiento y «me gusta».

16.5 Ausencia de relaciones explicitas entre autores

El conjunto contiene unicamente comentarios principales: reply_count indica que hubo 51 respuestas en total, pero ninguna de ellas esta en los datos ni se sabe quien las escribio. reply_count indica el volumen de respuestas pero no su autoria, de modo que **no existe ninguna relacion autor-autor observable en los datos**. **Restringe:** toda la interpretacion de la red. Las aristas son de co-participacion, no de interaccion. No se puede reconstruir ningun hilo, medir reciprocidad, detectar discusiones ni identificar influencia. Es la limitacion que fija el marco conceptual de todo el laboratorio.

16.6 Solo comentarios principales

Los 51 comentarios de respuesta que se sabe que existen no estan en el conjunto. **Restringe:** cualquier medida de conversacion, de profundidad de hilo o de participacion sostenida. Un usuario que respondio activamente a otros aparece en estos datos como si no hubiera participado.

16.7 Concentracion de comentarios en muy pocos videos

Dos videos concentran la mitad de los comentarios y el video lider el 39.7%. **Restringe:** la estabilidad de todos los agregados globales, que estan dominados por unos pocos hilos. La distribucion global de sentimiento, por ejemplo, esta determinada en un 40 % por un unico video sobre gastos de diputados. Por eso todas las comparaciones de esta seccion se hacen por grupo y con el n visible, en lugar de confiar en el promedio global.

16.8 Limites del sentimiento automatico

El modelo se entreno con tweets de 2020 (TASS) y se aplica a comentarios de YouTube de Guatemala: hay salto de dominio, de plataforma y de variedad dialectal. Falla sistematicamente en ironia, sarcasmo, slang guatemalteco («shucos», «tambo», «moronga»), ortografia no normativa y comentarios muy cortos; 40 predicciones (9.8%) tienen margen menor a 0,2 entre las dos clases principales. **No existe un conjunto etiquetado a mano de este dominio, por lo que no se puede reportar exactitud ni F1. Restringe:** toda interpretacion de polaridad. Las cifras describen lo que el modelo predijo, no lo que los autores quisieron decir. El detalle completo, con dieciseis limitaciones documentadas, esta en `results/model/sentiment_model_report.md`.

16.9 Posible sesgo por seleccion de videos y canales

Los canales presentes en los comentarios son 8 de 97 (8.2%) y estan sesgados hacia periodismo de investigacion, noticieros y comunicacion institucional. **Restringe:** la comparacion de sentimiento entre tipos de emisor, que se estima sobre ocho canales y podria invertirse con otra seleccion.

16.10 Los datos no representan a los usuarios de YouTube

Los 332 autores son quienes **comentaron** y cuyos comentarios **fueron recolectados**. Quien ve videos sin comentar —la inmensa mayoria— no aparece. Los comentaristas son un grupo autoseleccionado que no es representativo ni de la audiencia de esos videos. **Restringe:** cualquier afirmacion sobre «los usuarios de YouTube» o «la audiencia».

16.11 Los datos no representan a la poblacion de Guatemala

No hay marco muestral, ni ponderaciones, ni informacion demografica, ni verificacion de que los autores esten en Guatemala. La muestra es de conveniencia. **Restringe:** toda inferencia poblacional. Frases como «los guatemaltecos opinan...» no tienen sustento en estos datos y no aparecen en este informe.

16.12 Descripcion, asociacion e inferencia

Tabla 72. Los tres niveles de afirmacion y como se usan en este informe

Nivel	Formulacion	Ejemplo de este informe	Que autoriza
Descripcion	«En los datos observados...»	«El 61,6 % de los comentarios se clasifico como negativo.»	Afirmar el hecho sobre la muestra. Es el nivel de la mayoria de este informe.
Asociacion	«Se observa una relacion / correlacion...»	«Visualizaciones y comentarios observados correlacionan con $\rho = 0,81$ ($p = 2e-05$).»	Afirmar que dos cantidades covarian en la muestra. No autoriza a hablar de efecto, causa ni mecanismo.
Inferencia	«No puede inferirse...»	«No puede inferirse que la negatividad reduzca los «me gusta», ni que estos resultados describan a la poblacion de Guatemala.»	Nada, en este trabajo. No hay disenio muestral que sostenga inferencia poblacional ni disenio experimental que sostenga inferencia causal.

La consecuencia practica es que **todas las conclusiones de este informe son descriptivas o asociativas y estan acotadas a los 406 comentarios recolectados de 19 videos**. Cuando aparece una relacion entre variables se reporta su magnitud, su valor p y su n, y se declara explicitamente que no implica causalidad.

17. Conclusiones

Las conclusiones integran los tres bloques del analisis en lugar de resumirlos por separado, porque el resultado principal solo aparece al cruzarlos.

17.1 Conclusion integrada

Lo que estos datos describen no es una red social sino un patron de consumo de contenido con opinion adjunta. Las tres fuentes de evidencia convergen en ese punto. La *estructura* muestra estrellas casi disjuntas: 93.2% de los nodos con grado 1, asortatividad -0.428, $\kappa = 1$ en la componente mayor y 11 aristas entre 19 videos. El *contenido* muestra redacciones individuales sin coordinacion: el trigramma mas frecuente aparece 3 veces en 406 comentarios. Y el *sentimiento* muestra opinion evaluativa densa —61.6% de critica— pero dirigida al contenido y a sus protagonistas, no a otros comentaristas: no hay interpelacion mutua porque casi nadie coincide dos veces con nadie.

El mecanismo que articula las tres observaciones es la **falta de reincidencia**. Solo 9 de 332 autores (2.7%) comentaron en mas de un video. Ese unico numero explica por que la red esta fragmentada en 10 componentes, por que la audiencia compartida es minima, por que basta retirar a una persona para partir la componente principal, y por que solo 7 personas califican como puentes. La topologia no es una propiedad emergente compleja: es la consecuencia directa de que comentar en YouTube sea, en esta muestra, un acto puntual.

17.2 Lo que si permite afirmar el analisis

- **La concentracion observada es de atencion, no de voz.** Gini de 0.6596 por video y 0.6644 por canal frente a solo 0.1643 por autor. Pocos contenidos capturan casi toda la participacion; dentro de ellos, cientos de personas hablan una sola vez.
- **La red de co-participacion es real pero tenue y fragil.** 11 conexiones entre videos, pesos de 1 o 2, 9 videos aislados, κ global 0 y $\kappa = 1$ en la componente mayor. Las conexiones las sostienen 7 personas verificadas por prueba de eliminacion, no una malla redundante.
- **La estructura de audiencia coincide con la estructura tematica sin haberla usado.** Louvain vio solo numeros de autores compartidos y devolvio 3 comunidades cuyos terminos TF-IDF, keywords del emisor y distribucion de sentimiento convergen en tres campos distintos, ordenados por la relacion del comentarista con el poder institucional.
- **El sentimiento distingue tipos de emisor mas que temas.** Diferencia significativa entre canales (V de Cramer = 0.3244): el unico canal con mayoria positiva es una institucion municipal presentando un plan urbano; el periodismo de investigacion y los noticieros concentran la critica.
- **Existen dos registros de participacion.** Los comentarios negativos son mas largos (132 vs 76 caracteres de mediana) y reciben menos aprobacion (0 vs 2 «me gusta»); los positivos usan el doble de emojis.
- **La visibilidad ordena la participacion pero no el papel estructural.** $\rho = 0.8115$ entre vistas y comentarios observados, pero el video mas visto del corpus (304 089 vistas) tiene grado 0 en la red de audiencia compartida.

17.3 Lo que el analisis no permite afirmar

- **Nada sobre interaccion entre usuarios.** Los datos no identifican quien respondio a quien. Toda arista es co-participacion.
- **Nada sobre aislamiento real.** Un video sin audiencia compartida en estos datos puede tenerla en YouTube; con comentarios en solo 6.5% de los videos, la no-deteccion es el resultado esperado.
- **Nada causal.** Ni entre visibilidad y participacion, ni entre sentimiento y aprobacion, ni entre tema y polaridad. No hay diseno que lo sostenga.

- **Nada poblacional.** Ni sobre los usuarios de YouTube, ni sobre la audiencia de estos videos, ni sobre la poblacion de Guatemala. La muestra es de conveniencia, sin marco muestral ni informacion demografica.
- **Nada sobre la intencion de los autores.** Las etiquetas de sentimiento son predicciones de un modelo entrenado en otro corpus, sin acceso al video, al hilo ni al contexto cultural.
- **Nada temporal.** Sin fechas absolutas de comentario no hay evolucion, tendencia ni normalizacion por antigüedad.

17.4 Que haria falta para ir mas alla

- **Comentarios de respuesta con su autoria** (parentId y authorChannelId de la API de YouTube). Es el unico dato que convertiria una red de co-participacion en una red de interaccion, y sin el ninguna cantidad de comentarios principales alcanza.
- **Cobertura completa de comentarios en un subconjunto de videos**, incluso si es pequeno. Es preferible el censo de comentarios de 20 videos a una muestra parcial de 200: solo asi el aislamiento observado seria interpretable.
- **Marcas temporales absolutas** (publishedAt de la API) para normalizar acumulados por antigüedad y estudiar evolucion.
- **Un conjunto de validacion etiquetado a mano** de unos 300 comentarios de este dominio, para reportar exactitud y F1 del clasificador de sentimiento en lugar de describir solo su distribucion de salida.
- **Un diseno de muestreo declarado** (probabilistico o al menos documentado en sus criterios de inclusion) que permitiera acotar el sesgo de seleccion en lugar de solo diagnosticarlo.

18. Reproducibilidad

18.1 Como reproducir el analisis completo

Todo el analisis se reconstruye desde cero con un unico comando desde la raiz del proyecto:

```
git clone <repositorio> && cd cc3084-lab6-youtube
uv sync
uv run python -m spacy download es_core_news_sm
uv run python -m src.run_all
```

Alternativamente, `./scripts/run_analysis.sh` encapsula los mismos pasos, incluida la descarga de los recursos de NLTK y del modelo de spaCy, y verifica el resultado. El pipeline ejecuta en orden: validacion de los datos, limpieza y preprocesamiento, analisis exploratorio, construccion de las redes, calculo de metricas topologicas, deteccion de comunidades, centralidades y articulaciones, analisis de sentimiento, generacion de todas las tablas y figuras, y produccion de este informe en Markdown y PDF. Al terminar valida que existan todos los entregables obligatorios y devuelve codigo de salida distinto de cero si falta alguno.

18.2 Semillas y determinismo

Tabla 73. Fuentes de aleatoriedad y su control

Componente	Semilla / configuracion	Efecto
Global (random, numpy, PYTHONHASHSEED)	42	Fijada en <code>src/config.py::set_seeds</code> , invocada al inicio de cada etapa
Louvain	<code>seed=42, resolution=1.0</code>	El resultado de Louvain depende del orden de recorrido; con semilla fija la particion es identica entre corridas
Betweenness	<code>seed=42</code>	networkx acepta semilla para el muestreo de pivotes; aqui se calcula exacto
Label propagation (control de robustez)	<code>seed=42</code>	Comparacion reproducible
Trazado de las redes	<code>spring_layout(seed=42)</code> y trazados deterministas	Las figuras de red son identicas entre corridas. Los trazados de las dos proyecciones son construcciones deterministas propias (ver secciones 9.4 y 10)
Nube de palabras	<code>random_state=42</code>	Imagen identica entre corridas
Inferencia de sentimiento	<code>torch.manual_seed(42), model.eval()</code>	La inferencia es determinista por naturaleza (sin dropout ni muestreo); la semilla se fija de todos modos
TF-IDF	sin aleatoriedad	Determinista

18.3 Entorno y versiones

Tabla 74. Entorno de ejecucion

Componente	Version / valor
Python	3.13.14
Plataforma	Linux 6.18.33.2-microsoft-standard-WSL2 (x86_64)
Gestor de dependencias	uv (pyproject.toml + uv.lock)
pandas / numpy / scipy	3.0.5 / 2.5.3 / 1.18.1
networkx	3.6.1
scikit-learn	1.9.0
matplotlib	3.11.1
spaCy + modelo	3.8.16 + es_core_news_sm 3.8.0
NLTK	3.10.3
transformers / torch	5.16.1 / 2.14.0+cu130
reportlab (generacion del PDF)	5.0.1
Modelo de sentimiento	pysentimiento/robertuito-sentiment-analysis
Dispositivo de inferencia	cpu

18.4 Integridad de los datos de entrada

Los archivos de `data/raw/` son inmutables durante el análisis y se versionan sin conversión de fin de línea (via `.gitattributes`) para que sus sumas MD5 sigan coincidiendo tras clonar en cualquier sistema operativo: `d338be279d181215295037b0c938862b` (`youtube_videos.csv`) y `c45c1dcc72e33971106845e6a9674b9e` (`youtube_comments.csv`). El pipeline recalcula y registra ambas sumas en cada corrida.

18.5 Inventario de salidas

Tabla 75. Salidas generadas por el pipeline

Ubicacion	Contenido	Cantidad
<code>results/figures/</code>	Figuras en PNG a 300 dpi	29 archivos
<code>results/tables/</code>	Tablas completas en CSV	36 archivos
<code>results/networks/</code>	Tablas de nodos y aristas + GraphML	10 archivos
<code>results/metrics/</code>	Bloques de métricas en JSON que alimentan el informe	19 archivos
<code>results/model/</code>	Reporte y metadatos del modelo de sentimiento	2 archivos
<code>data/processed/</code>	Datos limpios y conjunto integrado	3 archivos
<code>report/</code>	Informe en Markdown y en PDF	2 archivos
<code>docs/</code>	Enunciado, metodología, checklist de rubrica y de entrega	4 archivos

18.6 Trazabilidad de las cifras del informe

Ninguna cifra de este documento está escrita a mano. El informe se genera a partir de los 19 bloques de métricas de `results/metrics/*.json` y de las tablas de `results/tables/*.csv`, que a su vez producen los scripts de análisis. Los pies de figura también se calculan en el momento de generar cada gráfico y se persisten en `results/figures/_captions.jsonl`. La consecuencia práctica es que si cambiaran los datos de entrada, el texto del informe cambiaría con ellos y no podría quedar inconsistente con los resultados.

18.7 Validaciones automáticas

El proyecto incluye una batería de pruebas (`uv run pytest`) que valida los puntos críticos sobre los resultados **calculados**, no sobre valores fijados a mano: dimensiones de los dos archivos, unicidad de las llaves primarias, ausencia de identificadores vacíos, integridad del join, comportamiento del parser numérico caso por caso, que la suma de pesos de la red bipartita sea igual al número de comentarios, que exista una sola arista por par autor-video, que todos los extremos de las aristas existan en la tabla de nodos, que los pesos de las dos proyecciones coincidan con un recalcu independentemente por intersección de conjuntos, que `reply_count` no se haya usado para crear aristas, que ninguna métrica sea NaN sin explicación, que cada comentario tenga salida de sentimiento y que existan todos los archivos obligatorios.

Además, el propio pipeline aborta con `AssertionError` si alguna de las nueve invariantes de la red bipartita o alguna de las verificaciones de pesos de proyección falla, de modo que no es posible generar el informe sobre una red mal construida.

Referencias

- Blondel, V. D., Guillaume, J.-L., Lambiotte, R. y Lefebvre, E. (2008). *Fast unfolding of communities in large networks*. Journal of Statistical Mechanics: Theory and Experiment, 2008(10), P10008.
- Clauset, A., Newman, M. E. J. y Moore, C. (2004). *Finding community structure in very large networks*. Physical Review E, 70(6), 066111.
- Freeman, L. C. (1977). *A set of measures of centrality based on betweenness*. Sociometry, 40(1), 35-41.

- Hagberg, A., Schult, D. y Swart, P. (2008). *Exploring network structure, dynamics, and function using NetworkX*. Proceedings of the 7th Python in Science Conference (SciPy2008), 11-15. Documentacion: <<https://networkx.org/documentation/stable/>>
- Latapy, M., Magnien, C. y Del Vecchio, N. (2008). *Basic notions for the analysis of large two-mode networks*. Social Networks, 30(1), 31-48.
- Menger, K. (1927). *Zur allgemeinen Kurventheorie*. Fundamenta Mathematicae, 10, 96-115. (Teorema que relaciona conectividad por nodos y caminos disjuntos.)
- Newman, M. E. J. (2003). *Mixing patterns in networks*. Physical Review E, 67(2), 026126. (Asortatividad de grado.)
- Newman, M. E. J. (2004). *Analysis of weighted networks*. Physical Review E, 70(5), 056131.
- Newman, M. E. J. y Girvan, M. (2004). *Finding and evaluating community structure in networks*. Physical Review E, 69(2), 026113. (Modularidad.)
- Perez, J. M., Furman, D. A., Alonso Alemany, L. y Luque, F. (2022). *RoBERTuito: a pre-trained language model for social media text in Spanish*. Proceedings of LREC 2022, 7235-7243. <<https://aclanthology.org/2022.lrec-1.785/>>
- Perez, J. M., Giudici, J. C. y Luque, F. (2021). *pysentimiento: A Python Toolkit for Sentiment Analysis and SocialNLP tasks*. <<https://arxiv.org/abs/2106.09462>>
- Model card del modelo utilizado: `pysentimiento/robertuito-sentiment-analysis`. <<https://huggingface.co/pysentimiento/robertuito-sentiment-analysis>>
- TASS: Taller de Analisis Semantico de la SEPLN. Corpus de afinado del modelo de sentimiento (TASS 2020, Task 1). <<http://tass.sepln.org/>>
- Wasserman, S. y Faust, K. (1994). *Social Network Analysis: Methods and Applications*. Cambridge University Press. (Correccion de closeness en grafos desconectados; nociones de cohesion.)
- Honnibal, M. y Montani, I. (2017). *spaCy 2: Natural language understanding with Bloom embeddings, convolutional neural networks and incremental parsing*. Modelo `es_core_news_sm`. <<https://spacy.io/models/es>>
- Bird, S., Klein, E. y Loper, E. (2009). *Natural Language Processing with Python*. O'Reilly. (Lista de stopwords de espanol de NLTK.)
- Universidad del Valle de Guatemala, Departamento de Ciencias de la Computacion. *CC3084 Data Science. Laboratorio 6: Analisis de redes sociales*. Semestre II, 2026. (Enunciado en docs/.)

Apendice A. Trazabilidad con los incisos del enunciado

Correspondencia entre cada inciso del enunciado del laboratorio y la seccion de este informe donde se resuelve. La auditoria completa contra la rubrica, con evidencia y estado por requisito, esta en `docs/rubric_checklist.md`.

Tabla A1. Inciso del enunciado y seccion del informe

Inciso del enunciado	Seccion de este informe
1.1-1.4 Carga, comprension e integracion	1, 2, 3
2.1 Diagnostico inicial de calidad	4.1
2.2 Variables problematicas	4.2
2.3 Normalizacion de IDs y nombres	4.3
2.4 Conversion de conteos en texto	4.4
2.5 texto_original y texto_limpio	4.5
2.6 Decisiones de limpieza documentadas	4.5.1
2.7 Efecto cuantificado de la limpieza	4.6
3.1 Descriptivos minimos	5.1
3.2 Concentracion de la participacion	5.2
3.3 Popularidad frente a participacion	5.3
3.4 Visualizaciones pertinentes	5 (figuras 1-14), 11, 13, 14
3.5 Seis preguntas obligatorias	6.1-6.6
3.6 Tres o mas preguntas adicionales	7.1-7.5 (cinco preguntas)
4.1-4.2 Red bipartita y definicion del peso	8.1
4.3 Tablas de nodos y aristas	8.4
4.4 Visualizacion de la red completa	8.5
4.5 Significado preciso de la arista	8.2
5.1 Proyeccion autor-autor	9.1-9.2
5.2 Proyeccion video-video	9.1-9.2
5.3 Comparacion de las proyecciones	9.3
5.4 Visualizacion de ambas proyecciones	9.4
6.1 Nodos, aristas, densidad, grados, componentes	10.1, 10.3, 10.4
6.2 Cohesion y transitividad	10.1, 10.2
6.3 Perifericos y aislados; aislamiento observado vs ausencia de datos	10.4
6.4 Explicacion de los hallazgos estructurales	10.5
7.1 Eleccion de la red y justificacion	11.1
7.2 Algoritmo, supuestos y pesos	11.2
7.3 Numero, tamanos y modularidad	11.3
7.4 Visualizacion de todas las comunidades y analisis de tres	11.4-11.5
7.5 Caracterizacion por videos, canales, autores, temas y sentimiento	11.5, 13.2, 14.4
8.1 Medidas de centralidad y justificacion	12.1
8.2 Interpretacion separada de autores y videos	12.2, 12.4
8.3 Recurrentes, puentes y videos articuladores	12.3, 12.5
9.1 Sentimiento en espanol y justificacion del modelo	14.1-14.3
9.2 Comparacion por video, canal, tema o comunidad	14.4
9.3 Explicacion de los hallazgos	14.5-14.6, 15.5
10.1 Hallazgos en contexto de participacion y consumo	15
10.2 Limitaciones minimas exigidas	16.1-16.11
10.3 Descripcion, asociacion e inferencia	16.12
10.4 Conclusiones integradas	17

Apendice B. Inventario de figuras

Tabla B1. Figuras generadas, con su archivo y su interpretacion

Archivo	Interpretacion (generada por el pipeline)
01_missing_values.png	Solo 4 variables de videos tienen faltantes (<9%). En comentarios, viewer_rating esta vacia al 100% y like_count_text aparece en blanco en 189 registros (46.6%), que se interpretan como 0 me gusta.
02_comments_by_video.png	Los 19 videos con comentarios recolectados concentran los 406 comentarios. El video mas comentado acumula 161 comentarios (39.7% del total). La cercania entre barras indica que casi cada comentario proviene de un autor distinto.
03_comments_by_channel.png	Solo 8 de 97 canales del catalogo tienen comentarios recolectados. El canal lider aporta 256 comentarios (63.1%) distribuidos en 11 videos.
04_category_distribution.png	El catalogo esta dominado por News & Politics (138/293 = 47.1%), pero los comentarios observados lo estan aun mas: la cobertura de comentarios no es proporcional al catalogo, es un submuestreo sesgado hacia unos pocos canales.
05_source_queries.png	Las 21 consultas del catalogo se reducen a 6 en los comentarios. La consulta '@quorumgt/videos' aporta 231 comentarios (56.9%): la cobertura de comentarios responde al procedimiento de recoleccion, no a la popularidad del contenido.
05_top_hashtags.png	Los hashtags viven en el contenido publicado por los canales (588 usos) y practicamente no en los comentarios (1 usos en 1 hashtags unicos sobre 406 comentarios). El etiquetado tematico es una practica del emisor, no de la audiencia en esta muestra.
06_top_words.png	Vocabulario politico-institucional: el termino mas frecuente aparece 56 veces en 10.3% de los comentarios. Ningun termino domina, lo que indica una conversacion tematicamente dispersa dentro de un mismo marco de referencia.
07_top_bigrams.png	El bigrama mas frecuente ('bernardo arevalo') aparece 10 veces. Las frecuencias bajas de los bigramas confirman que no existen consignas repetidas ni copy-paste masivo: los comentarios son redacciones individuales.
08_views_distribution.png	Cola derecha pesada: mediana 1,175 vistas frente a un maximo de 8,190,449 (ratio 6970x). La mediana de los videos con comentarios recolectados (1,954) frente a los que no los tienen (1,149) no difiere de forma significativa (Mann-Whitney U=2147.5, p=0.20265): la muestra de comentarios no es simplemente 'los videos mas vistos'.
09_views_vs_comments.png	Con n=19 videos, la correlacion de rangos entre visualizaciones y comentarios observados es $\rho=0.8115$ ($p=2e-05$), significativa al 5%: una asociacion monotona fuerte y positiva. Aun asi el video mas visto (304,089 vistas) no es el mas comentado (161 comentarios con 11,775 vistas). Ambos ejes son conteos parciales y la asociacion no implica causalidad.
10_participation_concentration.png	La participacion esta muy concentrada por video (Gini=0.6596) y por canal (Gini=0.6644), pero muy repartida por autor (Gini=0.1643): pocos videos reciben casi todo, y casi cada comentario proviene de una persona distinta.
11_wordcloud.png	Figura complementaria. No sustituye a los rankings cuantitativos de las figuras 7 y 8: el tamano de la nube no es comparable entre terminos con precision y no permite leer frecuencias.
12_engagement_distributions.png	El 46.6% de los comentarios no muestra 'me gusta' y solo 30 recibieron respuesta. 286 de 332 autores (86.1%) comentaron una unica vez: la participacion es mayoritariamente puntual, no conversacional.
13_degree_distribution_bipartite.png	Distribucion muy asimetrica: mediana 1 frente a maximo 3, y 99.4% de los nodos con grado ≤ 2 . La conectividad no esta repartida: se concentra en unos pocos nodos.
13_videos_per_channel.png	65 de 97 canales aportan un unico video. El catalogo se construyo mezclando busquedas por tema con barridos de canales especificos, lo que produce esta mezcla de canales muy representados y canales con un solo video.
14_bipartite_network.png	Red completa: no se elimino ningun nodo ni arista. La estructura dominante es de estrellas casi disjuntas (un video rodeado de autores de grado 1) unidas por unos pocos autores que comentaron en mas de un video. Una arista significa unicamente que el autor publico comentarios observados en ese video: no es amistad, respuesta, conversacion ni aprobacion.
15_bipartite_core_zoom.png	Vista ampliada COMPLEMENTARIA de la figura 15 (no la sustituye). Estos 9 autores son el unico mecanismo por el que los videos de la muestra quedan conectados entre si: el resto de autores tiene grado 1 y no aporta conexiones entre contenidos.
16_author_projection.png	Red completa. Los 10732 vinculos forman una clique por cada video observado: cada bloque denso es la audiencia de un video, no un grupo de amigos. Los 9 autores resaltados son los unicos que pertenecen a mas de un bloque y por tanto los unicos que pueden unir audiencias distintas.
17_video_projection.png	Red completa, incluidos los 9 videos aislados. El numero sobre cada arista es el numero de autores compartidos. Los pesos son 1 o 2: la audiencia comun entre videos es minima. Un video aislado lo esta EN LA MUESTRA, no necesariamente en YouTube.
18_degree_distribution_authors.png	Distribucion muy asimetrica: mediana 48 frente a maximo 183, y 2.7% de los nodos con grado ≤ 2 . La conectividad no esta repartida: se concentra en unos pocos nodos.

Archivo	Interpretacion (generada por el pipeline)
19_degree_distribution_videos.png	Distribucion muy asimetrica: mediana 1 frente a maximo 4, y 84.2% de los nodos con grado ≤ 2 . La conectividad no esta repartida: se concentra en unos pocos nodos.
20_video_communities.png	Se muestran las 12 comunidades, incluidos los 9 singletons (videos sin audiencia compartida observada). $Q = 0.4053$ indica una particion mejor que el azar, pero sobre una red muy dispersa: la modularidad de un grafo casi desconectado se obtiene facilmente y no debe leerse como comunidades tematicas robustas.
21_community_sizes.png	El tamaño de una comunidad en numero de videos no predice su intensidad de participacion: la comunidad con mas comentarios (225) tiene 4 videos, mientras que otras con mas videos acumulan mucho menos.
22_centrality.png	Solo 9 de 332 autores tienen $\text{betweenness} > 0$: la inmensa mayoría no intermedia nada porque pertenece a una sola clique de video. Fuerza y betweenness ordenan distinto, lo que confirma que un ranking de grado no basta para llamar 'puente' a un nodo.
23_centrality_correlation.png	Correlacion de rangos entre medidas. Grado, fuerza, PageRank y eigenvector miden casi lo mismo en estas redes, mientras que betweenness se separa: identifica una propiedad distinta (estar en el camino entre grupos) y es la medida pertinente para detectar puentes.
24_sentiment_distribution.png	El 61.58% de los comentarios se clasifica como negativo, 18.97% neutro y 19.46% positivo. La confianza mediana es 0.8685, y 3.94% de las predicciones tiene confianza < 0.5 , casos que deben leerse como indecision del modelo y no como neutralidad del autor.
25_sentiment_by_video_channel.png	El n de cada grupo aparece en su etiqueta: los grupos pequenos no son comparables. Restringido a canales con $n \geq 10$, la prueba chi-cuadrado da $\chi^2=82.0701$ ($gl=8$, $p=0.0$), significativa al 5%: V de Cramer = 0.3244.
26_sentiment_by_community.png	Las comunidades difieren en polaridad neta, pero la comparacion formal solo incluye las de $n \geq 10$. Chi-cuadrado: $\chi^2=100.3471$, $p=0.0$. La direccion del signo es el hallazgo interpretable; su magnitud exacta depende de muestras pequenas.
27_sentiment_vs_engagement.png	Los comentarios negativos tienen una mediana de 0.0 'me gusta' frente a 2.0 de los positivos. Es una asociacion descriptiva sobre conteos parciales al momento de la recoleccion, no evidencia de que la negatividad genere aprobacion.

Apendice C. Inventario de tablas exportadas

Las tablas del cuerpo del informe muestran top-N y resúmenes. Las versiones completas están en CSV:

Tabla C1. Tablas completas en results/

Archivo	Contenido	Filas
results/.../data_quality_videos.csv	Perfil de calidad por variable del catálogo de videos	20
results/.../data_quality_comments.csv	Perfil de calidad por variable de los comentarios	17
results/.../consistency_checks.csv	Chequeos de consistencia de IDs, nombres y handles	17
results/.../problematic_variables.csv	Variables problemáticas y su tratamiento	15
results/.../outlier_diagnostics.csv	Diagnóstico de atípicos por variable cuantitativa	10
results/.../cleaning_effect.csv	Efecto cuantificado de la limpieza de texto	28
results/.../videos_summary.csv	Un registro por video con metadatos y participación observada	293
results/.../comments_by_video.csv	Agregados de participación por video	19
results/.../comments_by_channel.csv	Agregados de participación por canal	8
results/.../authors_summary.csv	Un registro por autor con recurrencia y diversidad	332
results/.../eda_descriptives.csv	Descriptivos del análisis exploratorio	43
results/.../concentration_metrics.csv	Métricas de concentración (Gini, top-k, Lorenz)	7
results/.../top_words.csv	Palabras más frecuentes en texto_limpio	60
results/.../top_bigrams.csv	Bigramas más frecuentes	60
results/.../top_trigrams.csv	Trigramas más frecuentes	30
results/.../top_hashtags.csv	Hashtags de videos y de comentarios	339
results/.../top_video_keywords.csv	Keywords más frecuentes del catálogo de videos	120
results/.../top_emojis.csv	Emojis más frecuentes en los comentarios	44
results/.../bipartite_nodes.csv	Tabla de nodos de la red bipartita con atributos	351
results/.../bipartite_edges.csv	Tabla de aristas de la red bipartita con pesos	343
results/.../author_projection_edges.csv	Aristas de la proyección autor-autor	10 732
results/.../video_projection_edges.csv	Aristas de la proyección video-video	11
results/.../network_metrics.csv	Métricas topológicas de las tres redes (formato largo)	52
results/.../network_metrics_wide.csv	Métricas topológicas de las tres redes (una fila por red)	3
results/.../author_centrality.csv	Todas las centralidades de los 332 autores	332
results/.../video_centrality.csv	Todas las centralidades de los 19 videos	19
results/.../articulation_points.csv	Puntos de articulación con prueba de eliminación	34
results/.../bridge_authors.csv	Todos los autores con su evaluación como puente	332
results/.../communities.csv	Asignación de comunidad por video con atributos	19
results/.../community_summary.csv	Perfil completo por comunidad (tema y sentimiento)	12
results/.../community_tfidf_terms.csv	Terminos TF-IDF de los comentarios por comunidad	116
results/.../community_tfidf_keywords.csv	Keywords TF-IDF del contenido por comunidad	120
results/.../sentiment_predictions.csv	Predicción y probabilidades por comentario	406
results/.../sentiment_summary.csv	Distribución de sentimiento por video, canal, comunidad, categoría y consulta	48
results/.../sentiment_global_distribution.csv	Distribución global de clases	3
results/.../questions_answers.csv	Preguntas 3.5 y 3.6 con su respuesta	11